2025 年度修士論文

Balanced Diverse Strategy を用いた合成 Re-ID データの最適サブセット選択の検討

指導： 大木 哲史 准教授
西垣 正勝 教授
峰野 博史 教授

2026 年 2 月

静岡大学大学院 総合科学技術研究科 情報学専攻

724C-0042 竹田 優那

目次

第 1 章　序論 **1**
1.1　研究の背景 1
1.2　研究の目的 3
1.3　本論文の構成 3

第 2 章　準備 **5**
2.1　関連研究 5
2.1.1　ドメインギャップと合成データ活用の位置付け 5
2.1.2　ID 認識を考慮した学習データ合成 6

第 3 章　提案手法 **9**
3.1　問題設定 9
3.2　Balanced Diverse Strategy(BDS) の定義 9
3.2.1　記法と準備 10
3.2.2　クラスタ単位の割当 11
3.2.3　エントロピー保持型コア選択 12
3.2.4　幾何学的多様性拡張 13
3.2.5　全体後処理 14
3.2.6　BDS 全体のまとめ 15

第 4 章　提案手法の評価 **17**
4.1　評価目的 17
4.2　データセットと前処理 18
4.2.1　データセット 18
学習用データセット 19
評価用データセット 20
4.2.2　前処理 20
4.2.3　学習設定 21
4.2.4　評価環境 21
4.2.5　評価指標 22
4.2.6　ハイパーパラメータ設定 22
4.3　実験結果 22
4.3.1　実験１：ハイパーパラメータのグリッドリサーチによる性能評価 22

4.3.2 実験２：α の影響分析（β=0.7, γ=0.8 固定） 23
4.3.3 実験３：設計指標のアブレーション学習 25
4.3.4 実験４：ハイパーパラメータがサブセット構成に与える影響分析 26
γ sweep：Entropy Preservation の検証 27
α sweep 29
β sweep 32
sweep 実験全体を通した考察 34
4.4 考察と議論 36

第 5 章 結論 **41**

謝辞 **43**

参考文献 **45**

関連業績 **47**

第 1 章

序論

1.1 研究の背景

現代社会において，犯罪の未然防止や事件発生後の迅速な解決を目的として，街中やショッピングモールをはじめとする公共空間に多数の監視カメラが設置されている．その監視カメラを用いて，異なる監視カメラに映った人物が同一人物かどうかを，映像情報や画像情報に基づいて推定する技術として，Re-ID(Person Re-identification，以下 ReID とする) がある．ReID は事件発生後の追跡などの他に，商業施設での来店者の回遊分析などに用いられる．ReID の研究は，当初は色ヒストグラムや局所特徴量などのエンジニア自身が決めた特徴量を用いて，異なるカメラ間で同一人物を結び付ける手法が主流であった [1]．しかし，照明条件やカメラ視点の変化に弱く実環境での性能には限界があった．その後，深層学習の発展により，CNN(畳み込みニューラルネットワーク，Convolution Neural Network) を用いて人物画像から個人の識別に有効な特徴量を自動的に学習する手法が提案され，ReID 性能は大きく向上した．現在，ReID は深層学習に基づいて多くの研究がなされている．

実環境では，照明や視点，背景などの外観変動が大きいことから ReID のデータセットは多様で大規模である必要がある．また画像枚数が多いだけでは，同一人物の外観変動しか学習できず，多様な人物の識別性能を十分に出せない．そのため，ReID では画像量に加えて，多数の人物を含むデータセットが不可欠である [1, 2]．現在の ReID の研究で用いられてる代表的な大規模ベンチマークは Market-1501[3]，CUHK03[4]，MSMT17[5] が挙げられる．これらは実環境で非重複視点を複数のカメラで撮影された画像データセットである．数百〜数千の ID かつ数万〜十数万枚の画像を含んでいる．これらのデータセットは実環境に近い外観変動を含んでいるが，いくつかデメリットもあげられる．撮影場所やカメラ配置が限定されており服装や季節変化が少ないなど未知環境への ReID の汎化性能を十分に評価できない．また，アノテーションが理想的でノイズや欠損が少ないため実運用とのギャップが生じる可能性がある．これらを解決した大規模データセットを実環境で撮影する場合，問題が生じる．その問題とは，実社会では GDPR などの規制強化から高解像度で顔が映る場合の長期追跡が制限される場合が多い点である．

こうした背景から，フォトリアリスティックな 3D レンダリングエンジンによって生成される合成人物データセットが有力な代替手段として注目されている．例えば，PersonX[6] や RandPerson[7]，FineGPR[8] などが具体例として挙げられる．これらは，視点や背景，キャラク

ターの髪型や服装などの環境要因や属性を完全に制御可能で，ラベル付けコストも大幅に削減できるという利点を持つ．これらの合成データセットは，実データでは取得が困難な多様な外観変動や極端な視点変化を体系的に含めることが可能であり，ReID モデルに対して高い外観多様性を提供することができる．そのため，大規模かつ多様な人物データを効率的に構築できる点で，学習データ不足や ID 数不足といった従来の課題を緩和する有効なデータセットである．しかし，合成データは比較的容易に大量生産が可能である一方，過剰なデータ量が必ずしも ReID 性能の向上につながるとは限らない．合成データが過度に増加した場合，冗長なサンプルや実環境において寄与の小さい外観条件を含むデータが多数混在し，学習効率やモデル性能が減少する可能性がある [8]．

さらに，合成データセットでは，人物 ID ごとの画像生成数を任意に制御できる反面，人物 ID 分布が不均衡になりやすいという問題がある．特定の人物 ID に対して過剰なサンプルが生成された場合，学習データ全体としては画像枚数が十分であっても，実質的には限られた人物の外観変動のみを過度に学習することになる．このような ID 分布の偏りは，識別境界の過学習や，未観測人物に対する汎化性能の低下を引き起こす要因となることが指摘されている [1]．そのため，合成 ReID データの活用においては，外観の多様性だけでなく，人物 ID 分布の適切なバランスを考慮することが重要である．

一方で，計算資源や，学習時間の制約から合成データを削減して用いることが考えられるが，無作為なサンプリングによるデータ選択では，人物多様性や外観分布の偏りを適切に制御できないという限界がある [9]．その結果．識別に重要なサンプルが失われたり，逆に冗長なサンプルが残存するなど，学習データの質が十分に確保されない場合がある [1]．したがって，合成データの活用においては，単なるデータ量の確保や無作為な削減に依存するのではなく，ReID における識別性能に寄与するサンプルを選択的に活用するための体系的なデータ選択手法が求められている．

このような課題を踏まえると，合成データを有効に活用するには単にデータ量を削減するのではなく，サンプルの多様性を保持しつつ，特定の外観条件や人物に偏らないバランスの取れたデータ構成を実現することが重要である [8, 9, 1]．多様性のみを重視した場合には，実環境で撮影されたサンプルから遠いサンプルが過剰に選択される可能性がある．また，バランスのみを重視した場合には，識別に有用な外観変動が十分に含まれない恐れがある．したがって，ReID における合成データ選択では，外観，幾何学的多様性を確保しつつ，人物 ID の偏りを特性するという意味でのバランスを同時に満たす体系的なサンプル選択戦略が求められる．

この問題に対し，実データに対してクラス不均衡を是正するサブセット選択手法 (Balanced Active Sampling;BAS) [9] や，最遠点サンプリング (Farthest Point Sampling; FPS) に基づく大規模検索はオブジェクト ReID[10] で検討されており，バランスのよいサブセット選択が提案されてきた．しかし，多くの既存手法は幾何学的分散のみを最適化し，ラベルの多様性を無視するか，データセットサイズに比例または二乗してコストが増加する逐次的な距離更新を必要とする．ReID では，クラスタ内の外観変動が大きいため，BAS や FPS を合成データセットに用いる場

合，クラスバランスを無視するためドメインギャップがさらに悪化する可能性がある．

1.2　研究の目的

本研究では，合成データセットのうち最も現実に近いサブセットを抽出するにはどうしたら良いかという問いを明らかにするために，ラベル多様性を維持しつつ幾何学的カバレッジを最大化するエントロピー制約付き FPS 手法「Balanced Diverse Strategy(BDS)」を提案する．

本研究の仮説は，合成 ReID データにおいては，外観や姿勢が類似したサンプルの冗長性，人物 ID 分布の偏り，および実環境では観測されにくい非現実的な外観条件の混在という 3 つの要因が，実世界データへの汎化性能を体系的に阻害しているという点にある．本研究では，これらの要因が独立ではなく複合的に作用することで，合成データと実環境データとの分布的乖離を拡大させていると仮定する．この仮説に基づき，本研究では，合成データセットの中から，冗長性と ID 偏りを抑制しつつ，実環境に近い外観分布を保持したサブセットをいかに抽出できるか，という問いを設定する．

また，本研究の新規性について述べる．前節でも述べているのように，既存のサブセット選択は幾何学的分散 (FPS) または代表性 (BAS) のいずれかに主眼を置くことが多いため，合成データ特有の冗長性，ID 分布の偏り，非現実的外観の複合的影響を同時に抑制する枠組みは十分に整備されていない．そのため，本研究の新規性は合成 ReID データに対して，(1) 実世界分布への代表性，(2) 幾何学的カバレッジ (視覚的多様性)，(3) 人物 ID 分布の保持 (ラベル多様性) という 3 つの要件を同時に満たすサブセット構築問題として定式化し，大規模な合成データセットに対しても，現実的な計算時間でサブセット構築が可能であるという点にある．

提案手法 BDS は合成データセット FIneGPR からコンパクトで情報量の多い Resampled Dataset を抽出する．標準的なバックボーンをこのサブセットのみで学習し，Resampled Model を構築する．この Resampled Model を用いて実世界ベンチマーク Market-1501 で評価する．また，FIneGPR からランダムサンプリングしたサブセットを同条件で学習したモデルとの性能を比較し向上しているかを検証する．加えて代表性，多様性，人物 ID 保持を明示的に考慮したサブセット選択が ReID 性能に与える影響を明らかにする．

1.3　本論文の構成

本論文の構成を以下に示す．第 1 章では，本研究の背景および目的について述べる．第 2 章では，人物再識別に関する既存研究を整理し，ドメインギャップおよび合成データ活用に関する課題を明らかにする．第 3 章では，本研究で提案する Balanced Diverse Strategy（BDS）の設計思想およびアルゴリズムについて詳述する．第 4 章では，実験環境および評価指標を示した上で，提案手法の有効性を検証する実験結果を報告する．第 5 章では，得られた結果に基づく考察を行

い，本研究の限界および今後の課題について述べる．

第 2 章

準備

2.1 関連研究

2.1.1 ドメインギャップと合成データ活用の位置付け

ReID は，異なるカメラ間で同一人物を識別するタスクであり，監視映像解析や行動分析などへの応用が期待されている．しかし，ReID は撮影環境の違いに強く影響を受けるタスクであり，学習データと評価データの分布差，すなわちドメインギャップが性能低下の主要因となることが知られている．具体的には，カメラごとの視点差，照明条件，背景構造，解像度，人物の服装や姿勢といった要因が複雑に作用し，特徴分布の不一致を引き起こすとされている [11, 12, 13].

この問題は，異なる実世界データセット間においても顕著であり，あるデータセットで学習したモデルが，他のデータセットでは大幅に性能を低下させることが報告されている [14]．このようなクロスデータセット性能の低下を背景として，ReID 分野では，ドメイン適応やドメイン一般化に関する研究が活発に行われてきた．一方で，実データのみを用いた場合，データ収集やアノテーションコスト，およびプライバシーの問題から，大規模かつ多様なデータセットの構築には限界があることも指摘されている [11, 15].

こうした背景から，3D エンジンを用いた合成データセットの生成は，人物再識別のための大規模データセット構築手法として注目されている．PersonX[6]，RandPerson[7]，FineGPR[8] などの提案は，視点や照明を完全に制御できることを特徴としている．これらの手法は，プライバシー問題を回避しつつ大量のデータを安価に生成できることや，大量のデータを低コストでラベル付けも可能である．しかし，これらの合成データは仮想環境に基づくため，仮想空間と現実世界との間に外観的，統計的な差異が存在し，依然としてドメインギャップやリアリズムの不足といった課題が残る．

近年では，合成データの質的向上や活用に焦点を当てた研究も進んでおり，Xiang らの”Less is more”のアプローチ [8] は，合成データに付随する詳細な属性情報を活用することで，効率的な学習を実現している．それでもなお，合成データで学習したモデルと実データで学習したモデルの性能差を完全に解消するには至っておらずさらなる工夫が必要とされている．本研究で提案する Balanced Diverse Strategy(BDS) は，こうした合成データから有効なサンプルを選択する手法として応用可能である．例えば，BDS で仮想環境から得られたデータを選択し，実ドメインで有効

なコアセットを構築することで，合成データの利点を活かしつつドメインギャップの影響を低減できる可能性があると考えられる．

大規模な 3D エンジン生成合成データセット (PersonX[6]，RandPerson[7]，FineGPR[8]) は，視点や照明を完全に制御できるが，現実画像とのドメインギャップが精度低下の主因になっている．このギャップに対処する研究は 2 つの流れに分類される．1 つ目はレンダリング画像を編集する画像変換手法 (AOST[8],SPGA[16] など) である．2 つ目は，データセットをリサンプリングするデータ選択手法 (Balanced Active Sampling[9],Farthest Point Sampling[17]) である．本研究で提案する BDS は後者に属し，レンダリング画像自体を変更せずに実画像とのギャップを縮小する点で画像変換手法と根本的に異なる．

2.1.2　ID 認識を考慮した学習データ合成

実データをもとに深層生成モデル (GAN や拡散モデル) を用いて新たな人物画像を生成し，ID ラベルの一貫性を保ったままデータ拡張を行う研究も活発である．DG-Net[18] は，人物を識別するために学習された特徴表現を，画像生成にも共有して用いることで，生成画像が人物 ID の識別に有効な情報を保持するように設計されている．識別ネットワークと生成ネットワークを統合的に学習することで生成画像が単に見た目の多様性を増やすだけでなく，ReID において識別的な特徴を保持することが可能となり，生成と識別が相互に保管される枠組みが示されたことで，ReID 性能の向上につながった．

同様に，FD-GAN[19] は，ID 判別性と姿勢多様性をを同時に考慮した損失設計を導入し，生成画像においても人物の識別性を維持することを目的としている．このような ID 一貫性制約を明示的に導入した生成モデルは，単純なデータ拡張と比較して，ReID 性能の向上に有効であることが報告されている．

PAC-GAN[20] は人物の姿勢変化に着目し，GAN を用いて異なる姿勢の人物画像を生成することで，クロスビュー ReID における姿勢差の影響を低減する手法である．姿勢条約付き生成により，実データでは十分に観測できない視点変化を補完し，モデルの汎化性能を高めることが可能となる．

これらの研究は，ID 一貫性を考慮したデータ生成が ReID の汎化性能向上に寄与することを示している一方で，生成モデルの学習自体に高い計算コストを要することや，生成画像の品質やリアリズムが性能に大きく影響するといった課題も指摘されている．特に，生成データ量の分布が不適切な場合，学習を阻害する冗長なサンプルや識別性の低い画像が混入する可能性がある．

これに対し，本研究で提案する BDS は，画像生成そのものを行うのではなく，既存の合成データまたは生成済みデータ集合から識別に有効なサンプルを選択することにより，ID の代表性，幾何学的多様性，および ID 多様性のバランスを考慮した学習データ構成を実現する点に特徴がある，このようなデータ選択に基づくアプローチは，GAN や拡散モデルによる新たな画像生成を必

要とせず，既存データの構成を最適化することで，人物 ID の一貫性と汎化性能の向上を図る点で，データそのものの設計に主眼を置くデータ中心学習の一形態として位置付けられる．

第 3 章

提案手法

3.1 問題設定

本研究が対象とする課題は，合成データのみを用いて学習した ReID モデルが，実世界データに対して十分な性能を発揮できないという点にある．近年，プライバシー保護やコストの観点から，FineGPR[8] や RandPerson[7] に代表される大規模合成データセットが ReID の研究において広く利用されつつある．しかし，これらの合成データは視点や照明条件を制御できる一方で，実画像とのドメインギャップを完全には解消できない．その結果，合成データをそのまま大量に用いて学習したモデルは，実環境において性能が著しく低下する傾向がある．この問題に対し，レンダリング画像自体を変換する手法も提案されているが，レンダラーやネットワーク構造への依存が大きく，運用コストが高いという課題がある．

そこで，本研究では合成データの「量」ではなく，「選び方」に着目する．すなわち，合成データを追加生成したり，レンダリング条件や画像表現そのものを変更するのではなく，既存の合成データセットから実世界にとって有用な情報を効率的に抽出することを目的とする．具体的には，合成データセットから実世界に有用な情報を多く含むサブセットを抽出することで，合成データのみを用いた学習であっても実データに対する性能を向上させることを目指す．このアプローチは，画像変換や再レンダリングを必要とせず，追加のアノテーション作業やネットワーク構造の変更も伴わないため，計算資源および開発コストの観点からも実運用に適した解決策であると考える．

3.2 Balanced Diverse Strategy(BDS) の定義

本研究では，合成データセット FineGPR から実世界に有効な学習サブセットを抽出するための手法として，Balanced Diverse Strategy(BDS) を提案する．BDS は，代表性，幾何学的多様性，およびクラスタ内ラベル多様性を同時に考慮し，大規模合成データセットから情報量の高いサブセットを構築することを目的とする．

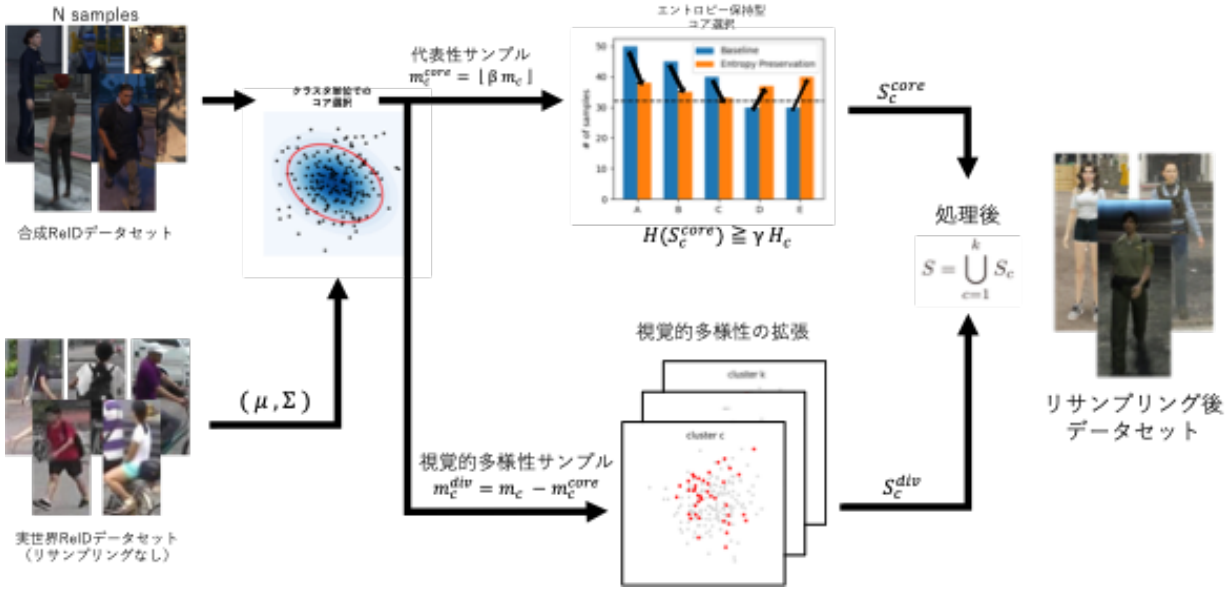

図 3.1　提案手法 BDS の概要

3.2.1　記法と準備

本研究では，画像そのものではなく，ReID モデルにより抽出された特徴空間上でサブセット選択を行う．そのため，以下では合成データセットを特徴ベクトルの集合として定式化する．合成データセットを

$$X = \{\mathbf{x}_i\}_{i=1}^{N} \subset \mathbb{R}^D \tag{3.1}$$

とする．ここで，N はサンプル総数，$\mathbf{x}_i \in \mathbb{R}^D$ は i 番目のサンプルに対応する特徴ベクトルである．各サンプル $\mathbf{x}_i$ には，離散的な ID ラベル $y_i \in \{1, \ldots, L\}$ が付与されている．

各サンプルの実世界に対する代表性を定量化するため，事前に定義した基準データセット（Market-1501）から推定した平均ベクトル $\boldsymbol{\mu}_{\mathrm{ref}}$ と共分散行列 $\boldsymbol{\Sigma}_{\mathrm{ref}}$ を用い，Mahalanobis 距離に基づく代表性スコア $d_i \in \mathbb{R}_{\geq 0}$ を次式で定義する：

$$d_i = \sqrt{(\mathbf{x}_i - \boldsymbol{\mu}_{\mathrm{ref}})^\top \boldsymbol{\Sigma}_{\mathrm{ref}}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_{\mathrm{ref}})}. \tag{3.2}$$

d_i が小さいほど，サンプル $\mathbf{x}_i$ は基準データセットの分布に近く，実世界に対する代表性が高いと解釈される．

次に，特徴空間上での局所構造を考慮するため，データセット X に対して k-means クラスタリングを適用する．各サンプルをクラスタに割り当てる写像を $g(\cdot)$ とし，クラスタ $c \in \{1, \ldots, k\}$ に属するサンプルのインデックス集合を

$$C_c = \{\, i \mid g(\mathbf{x}_i) = c \,\}, \quad n_c = |C_c| \tag{3.3}$$

と定義する．

表 3.1 本節で用いる記号一覧

記号	意味
N	元データセットのサンプル総数
D	特徴ベクトル $\mathbf{x}_i$ の次元数
α	残すデータの比率 $(0 < \alpha \leq 1)$，M を決定（式 (2)）
$M = \lceil \alpha N \rceil$	サブセットの目標サイズ（式 (2)）
k	k-means のクラスタ数
$g(\cdot)$	サンプルからクラスタインデックスへの写像
C_c	クラスタ c のインデックス集合，$n_c = \lvert C_c \rvert$ はそのサイズ
m_c	クラスタ c への割当数（式 (3)）
β	コア/多様性分割比率 $(0 < \beta \leq 1)$
$m_c^{\mathrm{core}} = \lceil \beta m_c \rceil$	クラスタ c のコアサンプル数
$m_c^{\mathrm{div}} = m_c - m_c^{\mathrm{core}}$	クラスタ c の多様性サンプル数
d_i	サンプル i の代表性スコア（式 (1)）
S_c^{core}	C_c から選択したコアサブセット（式 (6)）
$p_{c,\ell}$	クラスタ c の経験的ラベル分布（式 (4)）
H_c	$p_{c,\ell}$ の Shannon エントロピー（式 (5)）
γ	エントロピー保持比率 $(0 < \gamma \leq 1)$（式 (7)）
$R_c = C_c \setminus S_c^{\mathrm{core}}$	多様性サンプリング用の残差集合
S_c^{div}	FPS で R_c から選択した多様性サブセット（式 (8)）
$S_c = S_c^{\mathrm{core}} \cup S_c^{\mathrm{div}}$	クラスタ c の最終選択（式 (9)）
$S = \bigcup_{c=1}^{k} S_c$	全クラスタ処理後のグローバルサブセット（式 (10)）

データセット全体のうち割合 $\alpha \in (0, 1]$ を残す場合，目標とするサブセットサイズ M は

$$M = \lceil \alpha N \rceil \tag{3.4}$$

で与えられる．ここで α はユーザが指定するデータセット全体からサブセット選択比率を制御するための主要なハイパーパラメータである．

3.2.2 クラスタ単位の割当

本節では，各クラスタに対して選択すべきサンプル数を決定し，それを代表性を重視するコア部分と，幾何学的多様性を補完する多様性部分に分割する方法について述べる（記号の定義は表 3.1 を参照）．

まず，全体で選択するサンプル数を M とし，k-means クラスタリングによって得られた各クラスタ c（インデックス集合 C_c，サイズ $n_c = \lvert C_c \rvert$）に対して，元のクラスタサイズに比例した

割当数 m_c を与える．具体的には，

$$m_c = \left\lceil \frac{n_c}{N} M \right\rceil \tag{3.5}$$

と定義する．

この割当は，特徴空間上におけるクラスタサイズが元データ分布の局所的な密度を反映していると仮定し，サブセット全体として元の分布構造を大きく歪めることなく近似的に保持することを目的としている．その結果，大きなクラスタからは相対的に多く，小さなクラスタからは相対的に少ないサンプルが選択される．なお，著しく小さいクラスタに対しては割当数が過小となる可能性があるが，本研究では全体分布の代表性を優先する設計方針を採用する．

次に，各クラスタに割り当てられた m_c 個のサンプルを，代表性を重視するコア部分と，幾何学的な分散を重視する多様性部分に分割する．この分割比率を制御するため，ハイパーパラメータ $\beta \in (0, 1]$ を導入し，コアサンプル数 m_c^{core} を

$$m_c^{\mathrm{core}} = \lceil \beta m_c \rceil \tag{3.6}$$

と定義する．残りのサンプル数

$$m_c^{\mathrm{div}} = m_c - m_c^{\mathrm{core}} \tag{3.7}$$

は，多様性サンプルとして割り当てられる．

ここで，コア部分はクラスタ内における典型的な外観を捉えることを目的とし，代表性スコア d_i が小さいサンプルから優先的に選択される．これにより，実世界分布に近い特徴を持つ安定した学習サンプルを確保する．一方，多様性部分は，コア選択後に残されたサンプル集合から，クラスタ中心から離れた境界領域や外観変動の大きいサンプルを補完する役割を担う．

ハイパーパラメータ β は，代表性を重視するコア部分と多様性を補完する部分の分割比率を定めるコア比率であり，β を大きくするとクラスタ中心付近のサンプルが多く選択され，β を小さくすると多様性を重視したサブセット構成となる．

3.2.3　エントロピー保持型コア選択

本節では，各クラスタ内から代表的なサンプル (コアサンプル) を選択する方法を述べる．ReID では，同一クラスタ内であっても複数の ID が混在しており，代表性のみを基準にサンプルを選択すると，特定の ID に偏ったサブセットが構成される恐れがある．このような偏りは，学習過程において少数 ID に固有の外観特徴が十分に学習されず，識別性能の低下を招く要因となると考えられる．そこで本研究では，クラスタ内のラベル多様性を Shannon エントロピーによって明示的に制御する．

クラスタ c に属するサンプル集合 C_c に対し，ID ラベル $\ell \in \{1, \ldots, L\}$ の経験的分布を

$$p_{c,\ell} = \frac{1}{n_c} \sum_{i \in C_c} 1[y_i = \ell], \qquad \ell = 1, \ldots, L \tag{3.8}$$

と定義する．すなわち，(3.8) は，クラスタ c に含まれる n_c 個のサンプルのうち，ID ラベルが ℓ であるサンプルの個数を数え，それをクラスタ内の総サンプル数 n_c で正規化した割合を表している．

この経験的分布に基づき，クラスタ内のラベル多様性を表す Shannon エントロピーを

$$H_c = -\sum_{\ell=1}^{L} p_{c,\ell} \log p_{c,\ell} \tag{3.9}$$

と定義する．H_c が大きいほど，クラスタ内に多様な ID がより均等に含まれていることを意味する．

次に，クラスタ c から選択するコアサブセット $S_c^{\mathrm{core}} \subset C_c$ を，代表性スコア d_i の総和を最小化する集合として

$$S_c^{\mathrm{core}} = \arg\min_{S \subset C_c,\ |S| = m_c^{\mathrm{core}}} \sum_{i \in S} d_i \tag{3.10}$$

により定義する．この操作は，基準実データ分布に対して代表性の高いサンプルを優先的に選択することに相当する．

しかしながら，式 (3.10) による最適化では，出現頻度の高い ID に属するサンプルが優先的に選択されやすく，クラスタ内のラベル多様性が低下する可能性がある．特に，ReID では，出現頻度の低い ID が持つ外観特徴も識別境界の形成に重要であり，これからが学習データから欠落すると，汎化性能の低下を引き起こす恐れがある．この問題は，現実世界における ID 分布が必ずしも均等であるか否かとは独立して，学習データの縮約過程において生じる課題である．

そこで本研究では，コアサブセットにおいてもクラスタ内のラベル多様性を一定程度保持するため，次のエントロピー制約を課す：

$$H(S_c^{\mathrm{core}}) \geq \gamma H_c, \qquad \gamma \in [0, 1]. \tag{3.11}$$

ここで γ は，元のクラスタにおけるラベル多様性のうち，どの程度を保持するかを制御するハイパーパラメータである．$\gamma = 0$ はエントロピー制約を課さない場合に対応し，γ を大きくするほど，少数 ID を含む構成が強く要求される．

式 (3.11) を満たさない場合には，出現頻度の低い ID に属するサンプルを追加することでエントロピーを補正し，その後，代表性の低いサンプルを除外することで最終的に割当数 m_c^{core} を満たすよう調整する．この処理により，代表性とラベル多様性の両立が保証される．

3.2.4 幾何学的多様性拡張

前節では，各クラスタ内から代表性とラベル多様性を考慮したコアサンプル集合 S_c^{core} を選択した．しかし，これらのコアサンプルはクラスタ中心付近に集中する傾向があり，特徴空間全体を十分に被覆できない可能性がある．そこで本節では，特徴空間上の周縁領域や外観変動を補完するため，幾何学的多様性を考慮した追加サンプルの選択を行う．

まず，クラスタ c における残差集合を

$$R_c = C_c \setminus S_c^{\mathrm{core}} \tag{3.12}$$

と定義する．この集合 R_c から，多様性サンプルとして m_c^{div} 個のサンプルを選択する．

本研究では，既に選択されたコアサンプル集合との幾何学的重複を避けるための暗い的な実装例として，既存の選択点から十分に離れたサンプルを優先的に選択する Farthest-Point Sampling（FPS）を用いる．ただし，この段階は，Balanced Diverse Strategy（BDS）における多様性拡張の一手段であり，提案手法の本質は代表性およびラベル多様性を考慮したコア選択との段階的な組み合わせにある点が重要である．

具体的には，

$$S_c^{\mathrm{div}} = \arg\max_{S \subset R_c,\ |S| = m_c^{\mathrm{div}}} \min_{i \in S} \min_{j \in S_c^{\mathrm{core}} \cup S} \|\mathbf{x}_i - \mathbf{x}_j\|_2 \tag{3.13}$$

と定義した．この式 (3.13) に示しているのは，残差集合 R_c の中から，m_c^{div} 個のサンプル集合 S_c^{div} を，既に選択されたコアサンプル集合 S_c^{core} および選択途中の多様性サンプル集合との最小ユークリッド距離が最大となることを定義している．すなわち，各候補サンプルが既存の選択サンプル集合からどれだけ離れているかを評価し，その最小距離が最も大きくなるサンプルを優先的に追加することで，特徴空間上で広く分散した視覚的多様性の高いサブセットを構築する．実装上はこの基準に基づいて，Farthest-Point Sampling（FPS）を逐次的に適用する．

最終的に，クラスタ c における選択集合は

$$S_c = S_c^{\mathrm{core}} \cup S_c^{\mathrm{div}}, \qquad |S_c| = m_c \tag{3.14}$$

として得られる．

3.2.5　全体後処理

全てのクラスタに対して選択処理を行った後，グローバルな暫定選択集合を

$$S = \bigcup_{c=1}^{k} S_c \tag{3.15}$$

と定義する．ただし，各クラスタへの割当数 m_c は天井関数によって計算されるため，丸め誤差の影響により $|S| \neq M$ となる場合がある．

$|S| > M$ の場合には，選択集合 S に含まれるサンプルのうち，代表性スコア d_i が大きい $|S| - M$ 個のサンプルを除外する．一方，$|S| < M$ の場合には，未選択集合 $X \setminus S$ から，代表性スコア d_i が小さい $M - |S|$ 個のサンプルを追加する．

この後処理により，最終的に得られるサブセットは，目標サンプル数 M（式 (2)）を厳密に満たすとともに，全体として高い代表性を維持する．

3.2.6 BDS 全体のまとめ

本節では，合成データセットから効率的に学習サブセットを構築するための手法として，Balanced Diverse Strategy（BDS）を提案した．BDS は，特徴空間上でのクラスタ構造を基盤とし，代表性，幾何学多様性，およびラベル多様性の三つの観点を段階的に統合することで，冗長性を抑えつつ情報量の高いサブセットを抽出する．

これら三つの観点は，それぞれ，データセット全体からのサブセット選択比率を制御するパラメータの α，代表性を重視するコア部分と多様性を補完する部分の分割比率を定めるコア比率 β，およびクラスタ内のラベル多様性をどの程度保持するかを制御するエントロピー保持制約のパラメータ γ によって調整される．

具体的には，まず，クラスタ単位でサンプル数を割り当てることで，元データセットの分布構造を保ったサブセット構成を行った．次に，エントロピー保持型コア選択により，実世界分布に近い代表的なサンプルを選択すると同時に，特定の ID への偏りを防ぎ，クラスタ内のラベル多様性を維持した．さらに，幾何学的多様性拡張では，特徴空間の境界領域や外観変動の大きいサンプルを補完することで，サブセット全体のカバレッジを向上させた．最後に，全体後処理を通じて，目標サンプル数を厳密に満たすよう調整を行った．

これらの処理は，画像生成条件の変更や追加アノテーションを必要とせず，既存の合成データ資産および特徴表現をそのまま活用できるため，計算コストおよび運用コストの観点からも実用的である．以上により，BDS は合成データのみを用いた学習においても，実世界データに対する汎化性能の向上に寄与することが期待される．

第 4 章

提案手法の評価

4.1 評価目的

本章の目的は，提案手法 Balanced Diverse Strategy（BDS）が，合成データセット FineGPR から代表性，幾何学的多様性（FPS），およびラベル多様性を同時に考慮した学習サブセットを抽出できるかを検証することである．また，これらの設計指標およびハイパーパラメータが，ReID 性能およびサブセット構成に与える影響を，複数の実験により分析することである．

合成データは大規模かつ多様な外観変動を制御可能である一方，実世界データとの間には依然として視覚的なドメインギャップが存在する．そのため合成データ全体を一様に用いた学習では外観の姿勢や類似したサンプルの冗長性，特定の人物 ID への偏り，および実環境では観測されにくい非現実的な外観条件が混在しやすく，これらの実世界データへの汎化性能を阻害する要因となり得る．

本研究では，クラスタ代表性に基づくコア選択（Core），最遠点サンプリング（FPS）に幾何学的（視覚的）多様性の拡張（Diverse），ならびにクラスタ内ラベル分布のエントロピー制約によるラベル多様性の保持（Entropy Preservation）を統合することで，限られたサンプル数でも学習に有効な情報を高密度に含むサブセット構築が可能であると考える．

以上の問題意識に基づき，本研究では，合成 ReID データから学習に有効なサブセットを構築するためには，

1. 実世界分布への代表性
2. 視覚的多様性（幾何学的カバレッジ）
3. 人物 ID 分布の保持（ラベル多様性）

を同時に満たすことが重要であると仮定する．この仮定のもと，提案手法 BDS がこれらの要件を統合的に満たすことで，実世界データへの汎化性能を向上させるという仮説をたて，以下の 3 つの具体的仮説を設定する．

（H1）提案手法 BDS は，同一サブセットサイズにおいてランダム選択や単一指標手法より高い ReID 性能を示す

（H2）代表性，幾何学的多様性，ラベル多様性の各要素は相補的に性能へ寄与する

（H3）γ の制約により，ID 分布の歪みを抑える性能低下を防ぐことができる

これらの仮説を検証するため，まず，ハイパーパラメータ α, β, γ に対する粗いグリッドサーチを行い，提案手法 BDS の性能傾向を mAP および Rank 指標に基づいて把握する．さらに，合成データセット FineGPR から同一データ量を無作為に抽出したランダムサンプリングによるサブセットを構築し，提案手法によるサブセットとの ReID 性能を比較することで，サブセット選択戦略の違いが性能に与える影響を評価する（H1）.

次に，β および γ を固定した上で，α を広範囲に変化させる実験を行い，サブセットサイズと識別性能の関係を分析することで，（H2）を検証する.

さらに，BDS を構成する各設計要素の寄与を明確化するため，代表性，視覚的多様性，ラベル多様性をそれぞれ除去または組み合わせたアブレーション学習を行い，（H1）の妥当性を定量的に評価する.

最後に，α, β, γ を個別にスイープする実験を通じて，これらのパラメータがサブセットの内の分布構造に与える影響を分析する．特に，γ の変化に対して，Entropy Preservation 制約が意図通り機能しているかを検証し，（H3）が成立しているかを確認する.

具体的には, BDS が採用する代表性（Core)，視覚的多様性（Diverse)，ラベル多様性（Entropy）という 3 つの設計指標全てが，合成データセットから学習に有効なサブセットを構築できているかを明らかにすることを目的とする.

以上の実験を通じて，本研究は，BDS が有効に機能する条件と限界を明らかにするとともに，合成データを用いた ReID におけるサブセット選択戦略の設計指標を提供することが可能かどうかを評価目的とする.

4.2　データセットと前処理

4.2.1　データセット

本研究では，ReID における学習データの効率化と汎化性能の向上を目的として，合成データセットから学習に有効なサブセットを抽出す手法 Balanced Diverse Strategy（BDS）を提案する．本節では，提案手法の有効性を検証するために用いるデータセットについて述べる.

本実験では，学習用データセットと評価用データセットで性質の異なる複数のデータセットを用いる．学習には，プライバシー保護の観点から合成データセットのみを使用し，評価は実世界で撮影された標準的な ReID ベンチマークに対して行う．このようなデータセットの設定により，合成データから構築したサブセットが未知の実世界環境においても識別特徴を学習可能であるかを検証する.

学習用データセット

学習用データセットには，3D レンダリングエンジンを用いて生成された高精細な合成人物画像データセット FineGPR を用いる．FineGPR は，人物の外観，視点，照明条件，背景を制御可能な合成データセットであり，実画像を使用することなく大規模な学習データを構築できる点が特徴である．このため，プライバシー保護の観点からも，実運用を想定した ReID 研究に適したデータセットである．

本研究では，FineGPR に含まれる全サンプルをそのまま学習に用いるのではなく，提案手法 Balanced Diverse Strategy（BDS）を用いてサブセットを抽出し，そのサブセットのみを学習データとして用いる．これによりデータ量を削減とした条件下においても，学習に有効な情報を保持したデータ構成が実現できるかを検証する．

なお，BDS における代表性評価では，合成データ各サンプルが，実世界データの特徴分布に対してどの程度整合的であるかを定量的に評価するため，実世界データに基づく分布を導入する．本研究では，人物外観分布において広く利用されている Market-1501 の学習用分割を，実世界における人物外観分布を近似的に表す代表的なデータ集合として位置付ける．Market-1501 は，屋外の監視カメラ環境で撮影された人物画像から構成される大規模な人物再識別データセットであり，複数カメラ間での視点差，照明変化，背景の多様性など，実世界特有の外観変動を多く含んでいる．また，自動人物検出に基づく画像を含むため，検出誤差や背景ノイズも内包しており，実運用環境に近い人物外観分布を近似的に表現している点が特徴である．そのため，実環境における人物外観分布を近似的に表現するデータ集合として，多くの既存研究において広く利用されていることから，本研究でも Market-1501 を使用する．

一方，幾何学的多様性の観点では，合成データ集合内の特徴空間におけるサンプル間距離に基づき，外観のばらつきが大きくなるようサンプル選択を行う．BDS では，最遠点サンプリング（FPS）を用いることで，姿勢，視点，服装などの外観沿道を幅広く含むサブセット構成を実現する．これにより，代表性のみを重視した場合に生じ得る外観変動の不足を補完することが可能となる．

さらに，ラベル多様性の観点では，サブセット選択に伴って特定の人物 ID にサンプルが偏ることを防ぐため，クラスタ内の人物 ID 分布に基づくエントロピー制約を導入する．この制約により，外観的に類似したサンプルが選択される場合においても，特定の ID への集中を抑制し，サブセット内の人物 ID 分布の偏りを緩和することが可能となる．

このデータセットから得られる特徴分布を基準とすることで，合成データの各サンプルが，実世界データの分布に対してどの程度近い外観特有を有しているかを定量的に評価することが可能となる．BDS では，この基準分布との乖離度を用いて合成データの代表性を評価し，実世界データとの分布的整合性が高いサンプルを優先的に選択する設計となっている．

これにより，合成データのみを用いた学習条件下においても，実世界環境における人物外観の

多様性や分布構造を考慮したサブセット構築を実現することを目指す．なお，Market-1501 は代表性評価のための基準分布の構築にのみ使用し，学習データやハイパーパラメータ選択には用いない．この設定により，評価データとの情報的独立性を保ちつつ，合成データから実世界への汎化性能をきちんと検証する．

評価用データセット

提案手法 BDS により選択したサブセットを用いて学習したモデルの評価には，実世界で撮影された人物再識別ベンチマークデータセットを用いる．本節では，代表的な評価用データセットとして Market-1501 について述べる．

Market-1501 は，複数台の監視カメラによって撮影された歩行者画像から構成される大規模な人物再識別データセットであり，実環境における人物外観のばらつきやカメラ間差異を含む点で，人物再識別研究において広く利用されている標準的ベンチマークである，本研究では，Market-1501 を合成データのみで学習したモデルが実世界環境においてどの程度汎化性能を示すかを検証するための評価用データセットとして位置付ける．

評価に際しては，Market-1501 に含まれるクエリ画像およびギャラリー画像を用い，人物再識別における標準的な評価プロトコルに従って性能を算出する．なお，Market-1501 は学習データとしては一切使用せず，モデル学習およびハイパーパラメータ選択とは完全に独立した条件下で評価のみに用いる．

このような設定により，合成データから構築したサブセットを用いて学習したモデルが実世界データに対してどの程度有効な識別特徴を獲得できているかを評価することが可能となる．

4.2.2　前処理

本研究では，学習用データセットおよび評価用データセットに対して，人物外観を特徴ベクトルとして表現するための前処理を行う．本節では，特徴抽出，距離の解釈，特徴の正規化，クラスタリング，および各設計指標に基づく前処理の概要について述べる．

まず，人物画像からの特徴抽出には，ImageNet で学習された ResNet-50 を用いる．各人物画像は ResNet-50 に入力され，人物の外観を表す固定長の特徴ベクトルへと変換される．この特徴ベクトルは，服装の色や形状，姿勢，視点といった人物外観に関する情報を高次元空間上で統合的に表現したものである．

本研究では，この特徴空間上におけるサンプル間の距離関係を用いて，合成データのサブセット選択および人物再識別性能の評価を行う．すなわち，特徴ベクトル間の距離が近いほど，外観が類似しているとみなし，距離が大きいほど外観が異なる人物画像であると解釈する．

抽出された特徴ベクトルは，特徴量のスケール差が距離計算に与える影響を抑制するため，正

規化処理を施した上で用いる．これにより，特徴空間上における距離が外観の相対的な差異をより適切に反映するようになる．

さらに，本研究では，特徴空間の局所的な構造を考慮するため，合成データに対して k-means クラスタリングを適用する．k-means により，外観が類似したサンプル同士を同一クラスタとしてまとめることで，合成データ集合に含まれる外観分布の構造を近似的に表現する．本研究では，データ規模および計算量とのバランスを考慮し，クラスタ数を $k = 3000$ に設定した．

BDS における代表性評価では，合成データ各サンプルと実世界データの特徴分布との乖離度を定量化するため，特徴空間上での距離計算を行う．具体的には，実世界でーたから構築した基準分布に対して，各合成データサンプルがどの程度離れているかを距離指標として評価する．この距離は，実世界データの分布構造を考慮した尺度として定義され，BDS における代表性スコアの算出に用いられる．

一方，視覚的多様性の評価です，合成データ集合内における特徴ベクトル間の距離関係に基づき，外観のばらつきが大きくなるようサンプル選択を行う．これにより，姿勢，視点，服装などの外観変動を幅広く含むサブセット構成が可能となる．

そして，BDS ではサブセット選択に伴って特定の人物 ID にサンプルが偏ることを防ぐため，ラベル分布の不均衡を考慮した制約を導入している．これにより，外観の多様性だけでなく，人物 ID の偏りを抑制したサブセット構成が可能となる．

なお，本研究では，サブセット選択手法間の公平な比較を行うため，BDS により選択するサンプル数を $M = 10{,}000$ に固定し，すべての実験において同一のサブセットサイズで評価を行う．

以上の前処理により，合成データおよび実世界データを共通の特徴空間上で扱うことが可能となり，BDS に基づくサブセット選択および人物再識別性能の評価を一貫した枠組みで行う．

4.2.3　学習設定

学習は，各サブセットに対して一定のエポック数で実施する．学習エポック数は，合成データのみを用いた条件下において，検証性能が安定し，学習が十分に収束することを事前に確認した上で設定した．本研究では，すべての実験において学習設定（エポック数：60，最適化手法：SGD，初期重み）を統一し，サブセット構成以外の要因が評価結果に影響を与えないように配慮した．

また，学習率スケジュールやデータ拡張手法についても全実験で同一の設定を用い，各サブセット間の比較が学習データ構成の違いのみに基づくものとなるよう統制した．

4.2.4　評価環境

本研究における評価は，提案手法 Balanced Diverse Strategy（BDS）によって合成データセット FineGPR から抽出したサブセットのみを用いて学習した人物再識別モデルが，実世界データに対してどの程度汎化性能を有するかを検証することを目的として行った．

人物再識別モデルのバックボーンには，ImageNet で事前学習された ResNet-50 を用いた．FineGPR からリサンプリングしたサブセットのみを用いて ResNet-50 を学習し，実世界データに対してはファインチューニングを行わずに直接評価を行った．これにより，合成データから構築したサブセット自体の有効性を純粋に評価できる設定とした．

BDS における代表性評価の基準分布として，人物再識別研究で広く用いられている Market-1501 の学習用分割を用いた．このデータセットから得られる特徴分布（平均および共分散）を，実世界における人物外観分布を近似的に表す基準分布として位置付け，合成データ各サンプルの代表性を定量化した．

提案手法によって構築したサブセットで学習したモデルの評価には，実世界ベンチマークデータセットの一つである Market-1501 を使用した．

4.2.5　評価指標

人物再識別性能の指標評価として, Rank-k Accuracy (k = 1,5,10) および mAP (mean Average Precision）を用いる．Rank-k-Accuracy は，クエリ画像に対して正解人物 ID が上位 k 件の検索結果に含まれる割合を示す指標であり，検索性能の直感的な評価に用いられる．そして，mAP はランキング全体を考慮した指標であり，複数の正解候補を含む人物再識別タスクにおいてより包括的な性能評価を可能とする．

本研究では，これらの指標を用いて，BDS により構築されたサブセットが実世界データに対してどの程度有効な識別性能を示すかを評価する．

4.2.6　ハイパーパラメータ設定

本研究では，Balanced Diverse Starategy（BDS）におけるハイパーパラメータ α，β，γ を調整することで，サブセットの構成および人物再識別性能への影響を分析する．これらのパラメータは，サブセットサイズ，代表性，視覚的多様性，およびラベル多様性のバランスを制御する役割を持つ．

まず，パラメータ空間全体における性能傾向を把握するため，α，β，γ に対してグリッドサーチを行う．この検索結果を基に，以降の実験では代表的な設定を基準点としてサブセットの分析を行う．

4.3　実験結果

4.3.1　実験１：ハイパーパラメータのグリッドリサーチによる性能評価

本実験では，提案手法 Balanced Diverse Strategy（BDS）におけるハイパーパラメータ α, β, γ が人物再識別性能に与える影響を把握するため，粗いグリッドリサーチによる性能評価を行う．

この実験は第 4.1 節の（H1）が成立するかを検証する実験の一つとして行う．

パラメータ空間全体における性能傾向を把握するため，粗いグリッドサーチにより以下のような探索範囲を設定した．$\alpha \in \{0.1, 0.2, 0.3\}$，$\beta \in \{0.1, 0.3, 0.5, 0.7, 0.8, 0.9\}$，$\gamma \in \{0.1, 0.3, 0.5, 0.7, 0.8, 0.9\}$ を探索範囲とし，全 108 通りのパラメータ組み合わせについて実験を行った．これにより，

その結果，$\alpha = 0.10$，$\beta = 0.70$，$\gamma = 0.80$ の設定において最も高い識別性能が得られ，Market-1501 検証分割において Rank-1 精度 17.64% ，mAP 5.7% を達成した．これは，FineGPR から同一データ量を無作為に抽出したランダムサンプリングによるサブセットで学習したモデルと比較して，Rank-1 で 1.96% ，mAP で 0.86% の性能向上に相当する．向上幅は限定的ではあるものの，提案手法 BDS によるサブセット選択が，ランダムサンプリングと比較して，ReID 学習により有効なサンプル構成を実現できている可能性を示唆している．

本研究では，以降のすべての実験において，このパラメータ設定を固定して用いる．

さらに，実験 1 および本実験において得られた最適なハイパーパラメータ設定（$\alpha = 0.1$，$\beta = 0.7$，$\gamma = 0.8$）の汎化性を検証するため，テストデータセットを Market-1501 から CUHK03 に変更した追加実験を行った．その結果，rank-1 は 6.38% ，mAP は 5.41% であり，Market-1501 をテストデータセットとした場合と比較して，rank-1 および mAP の低下が確認された．

この性能低下の要因として，CUHK03 と Market-1501 の間に存在する撮影環境および人物外観分布の違いが考えられる．CUHK03 は主に屋内環境で撮影されたデータを含み，カメラ配置や背景条件が Market-1501 の屋外監視カメラ環境と異なる．その結果，Market-1501 を基準分布として選択されたサブセットが，CUHK03 に対しては十分な代表性を持たなかった可能性がある．

また，本研究の代表性評価は Market-1501 に基づく分布推定に依存しているため，評価対象となる実データセットが変化した場合には，最適なサブセット構成も異なる可能性がある．したがって，本結果は，BDS によるサブセット選択が特定の実世界分布に対しては有効である一方で，異なる撮影環境を持つデータセットに対しては，同一のハイパーパラメータ設定が必ずしも最適とは限らない

4.3.2　実験２：α の影響分析（β=0.7，γ=0.8 固定）

本実験では，BDS におけるサブセットサイズを制御するハイパーパラメータ α が，人物再識別性能を与える影響を調査する．実験 1 における粗いグリッドサーチの結果，α=0.1 の設定が最も高い性能を出したが，探索範囲が $\alpha \in \{0.1, 0.2, 0.3\}$ と比較的限定されていたため，α に関する最適性が十分に検証されたとは言い難い．

そこで本実験では，β=0.7，γ=0.8 を実験 1 で得られた最良設定として固定した上で，サブセット比率 α を 0.1 から 0.9 まで広げ，サブセットサイズの変化が性能に与える影響を系統的に評価する．これにより，サブセットとして使用するサンプル数を大きく変化させた場合においても実

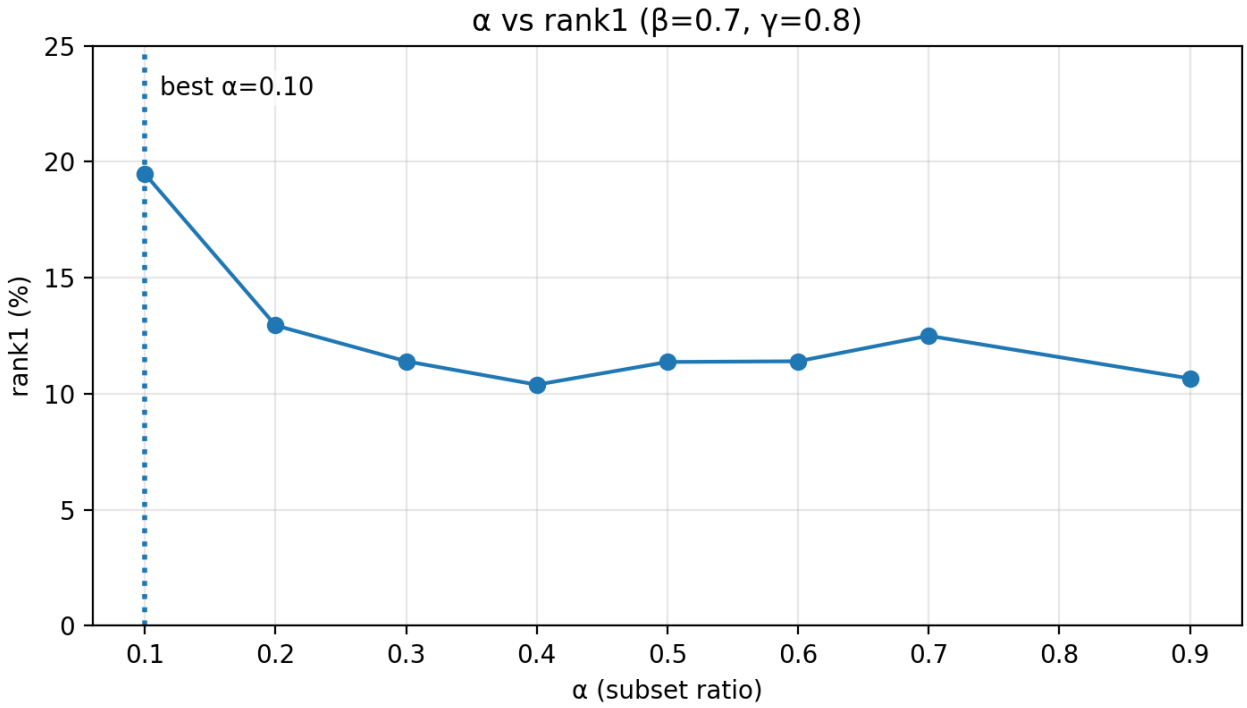

図 4.1　α vs rank-1

験 1 で得られた α=0.1 が最適な設定であるかを検証する．

α に対しての rank-1 の推移を図 4.1，α に対しての mAP の推移を図 4.2 に示す．rank-1 は α=0.1 において最も高い値（約 6.8% ）を示した．また同様に mAP についても α=0.1 が最大値（約 19.5% ）となった．α を 0.2 以上に増加させると，rank-1，mAP ともに一度大きく低下し，その後小さな変動は見られるものの，α=0.1 の性能には達していない．特に α=0.4 付近では両指標ともに低い値を示しており，α の増加が必ずしも性能向上につながらないことが確認できる．

本結果から，α を大きくしてサブセットサイズを増やした場合でも，必ずしも ReID 性能が向上するとは限らないことが示唆される．特に，α を 0.1 から増加させると mAP，rank-1 の双方が低下する傾向が見られた．これらの要因は以下のものが考えられる．まず，サブセットサイズの増加に伴い，視覚的に冗長なサンプルや現実ドメインから乖離したサンプルがより多く含まれる可能性や，合成データ特有のノイズやバイアスが，α の増加によって学習に影響を与える可能性が考えられる．一方で，α=0.7 付近では一部性能の回復が確認されており，大規模サブセットが常に不利であると断定することはできない．ただし，今回の条件では，性能のばらつきが大きく，α を増加させることで安定した性能向上が得られるとは言い難い．

以上より，本実験範囲においては，少量であっても適切に選択されたサブセット（α=0.1）が，より大きなサブセットよりも有効に機能する場合があることが示唆された．

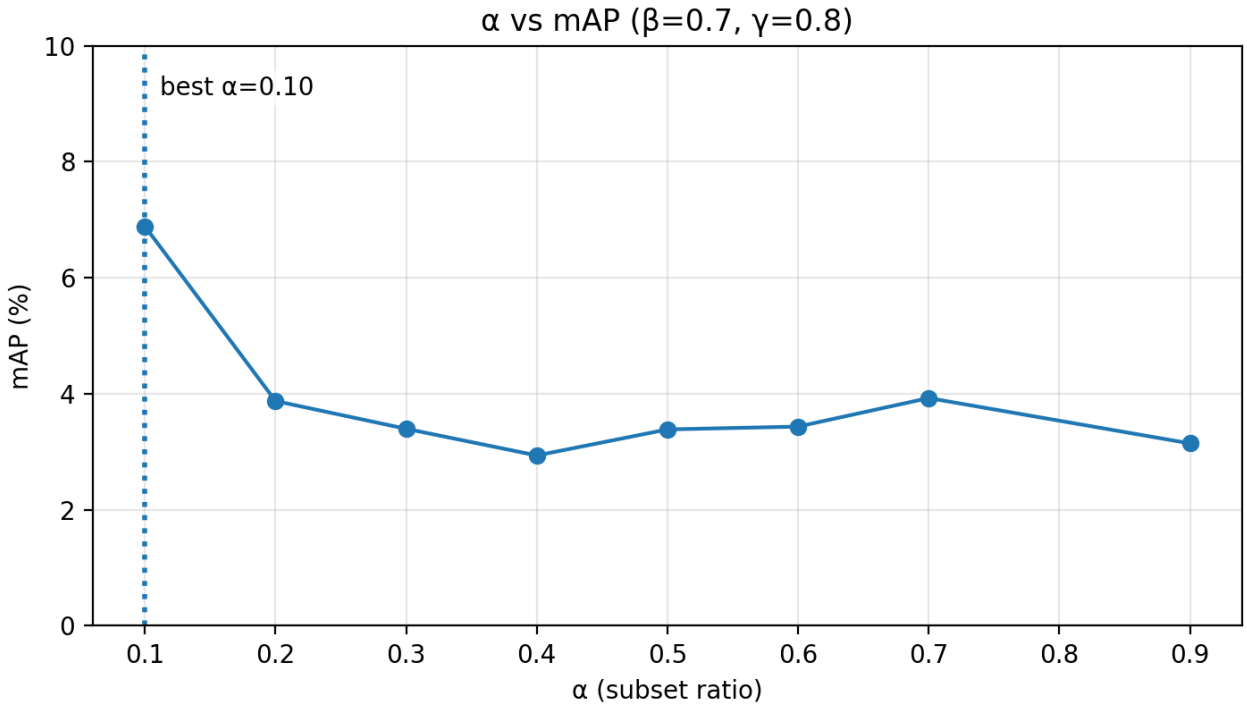

図 4.2　α vs mAP

4.3.3　実験３：設計指標のアブレーション学習

本実験では, 提案手法 BDS を構成する 3 つの設計指標, 代表性（Core）, 視覚的多様性（Diverse）, およびラベル多様性（Entropy）のそれぞれが人物再識別性能に与える寄与を明らかにするため, アブレーション学習を行う．これにより，BDS が単一の設計指標ではなく，複数の要素を組み合わせることで性能を向上させていることを定量的に確認するためである．

各設計指標を単独で用いた場合，および複数の設計指標を組み合わせた場合について，合計 7 通りのサブセット構成を比較する．具体的な比較対象とするサブセット構成は，Core のみ，Diverse のみ，Entropy のみ，Core+Diverse，Core+Entropy，Diverse+Entropy，および 3 つ全てを用いた構成（Core+Diverse+Entropy）の計 7 通りである．表 4.1 に提案手法 BDS を構成する各設計手法（Core，Diverse，Entropy）について，単独および組み合わせでサブセットを構成した場合の ReID 性能を示す．本実験では，これらの結果に基づき，各指標の寄与，および相互作用について考察する．

まず，単一指標のみを用いた場合に注目する．Core のみを用いた構成では，Rnak1 が 14.99%, mAP が 4.58% であった．Core は現実データに近い代表的サンプルを優先的に選択するため，ノイズの少ない学習データを構成できる一方で，ID 内外の外観変動が限定的である．その結果，ReID に必要な識別境界を十分に学習できず，性能が限定的であると考えられる．Diverse のみを

用いた構成では，Rank1 が 15.29% ，mAP が 4.74% と，Core 単体よりもわずかに高い性能を示した．これは最遠点サンプリング（FPS）により外観の分散が確保されたためと考えられる．しかし，ID 分布の不均衡や，現実データとの乖離が考慮されていないため，性能向上はそれほど見られなかった．一方，Entropy のみを用いた構成では Rank1 が 16.24% ，mAP が 5.24% と，単一指標の中でも最も高い性能を示した．これは，ID 後 t のサンプル数分布を均一化することで，特定の ID に偏った学習が抑制され，識別性能が向上したためと考えられる．この結果は，ReID において ID バランスが重要な要素であることを示唆している．

次に，2 指標を組み合わせた場合について考察する．Core+Diverse の構成では，Rank1 が 14.37% ，mAP が 4.39% といずれも単体の指標より低い性能となった．代表性と視覚的多様性を同時に考慮しているものの，ID 分布の不均衡が解消されておらず，学習に有効でないサンプルが含まれた可能性がある．この結果は，代表性と外観分散のみでは ReID 性能向上に不十分であることを示している．Core+Entropy の構成では，Rank1 が 15.88% ，mAP が 5.34% と，Core 単体から改善が見られた．これは代表的なサンプルを保持しつつ，ID 分布の偏りを抑制できたためと考えられる．一方で，Diverse を含まないため，外観変動は Entropy や Core より間接的には確保されるものの，幾何学的分散を明示的に最大化しているわけではない．Diverse+Entropy の構成では，Rank1 が 14.22% ，mAP が 4.51% と，Entropy を含むにも関わらず性能は低下した．これは，外観的な多様性を優先することで，現実データとの整合性が低下し，ドメインギャップが拡大した可能性を示唆していると考える．この結果から，多様性と ID バランスのみでは十分ではなく，現実性を担保する指標が必要であることがわかる．

最後に，Core，Diverse，Entropy の全てを統合した BDS では，Rank1 が 19.48% mAP が 6.86% と，全ての構成の中で最も高い性能を達成した，特に Entropy 単体と比較しても Rank-1 で 3.24% mAP で 1.65% の大幅な向上が確認された．この結果は，代表性，視覚的多様性，ID 分布の均衡という 3 つの設計指標が補完的に機能することで，高性能な学習サブセットが構成できることを示している．

以上より，合成データから ReID に有効な学習サブセットを構成するためには，単一または 2 つの設計指標では不十分であり，複数の指標を統合的に最適化することが重要であることが確認できた．BDS はこれらの要件を同時に満たす手法であり，合成データ活用における有効なサブセット選択戦略であることを示唆している．

4.3.4　実験 4：ハイパーパラメータがサブセット構成に与える影響分析

本実験では，BDS における各ハイパーパラメータがサブセット構成に与える影響を詳細に分析するため，α，β，γ をそれぞれ独立にスイープさせた実験を行う．本実験の目的は，人物再識別性能の変化だけでなく，サブセットに含まれるサンプルの分布構造やラベル分布の変化を定量的に調査し，各パラメータの役割を明確にすることである．

表 4.1　設計指標のアブレーション実験結果

サブセット構成	Rank-1 （%）	mAP （%）
Core	14.99	4.58
Diverse	15.29	4.74
Entropy	16.24	5.24
Core + Diverse	14.37	4.39
Core + Entropy	15.88	5.34
Diverse + Entropy	14.22	4.51
BDS （Core + Diverse + Entropy）	**19.48**	**6.89**

本実験では，実験１で得られた最良設定（α=0.1，β=0.7，γ=0.8）を基準構成とし，一つのパラメータのみを変化させ，残りのパラメータは固定した条件で分析を行う．

γ sweep：Entropy Preservation の検証

本研究で提案する BDS は，サブセット選択において量（α），代表性（β），多様性制約（γ）の３つのハイパーパラメータによって挙動が制御される．これらのうち γ は，サブセット内の ID 分布が過度に偏ることを防ぐ Entropy Preservation を担う制約パラメータであり，BDS が安定して機能するための前提条件に相当する．

特に α を増加させた場合や，代表性を優先する選択（β）を行った場合，多様性制約が十分に機能していなければ，サンプルが一部の ID に集中し，実質的な ID 多様性が失われる可能性がある．したがって，γ の役割とその影響を定量的に理解せずに他のハイパーパラメータを議論すると，その効果を十分に評価できない可能性がある．

そこで本実験では，α および β を固定した条件下で γ を，$\gamma \in \{0, 0.1, \ldots, 1.0\}$ で sweep する実験を行い，γ がサブセット構成，特に ID 分布の多様性および均一性にどのような影響を与えるかを検証する．本実験により，Entropy Preservation 制約がサブセット構成の崩壊を防ぐ上で果たす役割を明確にし，後続の実験，β sweep および α sweep における議論の前提を確立する．

■γ と ID 枚数不均衡（Gini 係数）の関係　まずは，全 γ の値において，選択されたサブセットにおける ID ごとのサンプル数分布の不均衡度を表す指標である Gini 係数の変動を調査する．Gini 係数は値が 0 に近いほど各 ID が均等な枚数で選択されており，値が大きいほど一部の ID にサンプルが集中していることを意味する．本研究では，サブセット全体における ID ごとのサンプル枚数の偏りを評価する目的で用いる．図 4.8 が，全 γ による Gini 係数の変動である．Gini 係数は γ を 0 から 1 まで変化させても，大きな変動を示さず，全体としてほぼ一定の値を保っている．変動幅は極めて少なく，γ の導入や増加によって ID ごとのサンプル枚数不均衡が顕著に悪

化していないことが確認される．

この結果は，Entropy Preservation 制約が，少なくともサブセット全体における ID 枚数の不均衡を悪化させないことを示している．

■γ とクラスタ内局所多様性（Hc_q25）の関係　次に，全 γ の値において，各クラスタ内の ID 分布から計算された Entropy を表す Hc の下位 25 %分位（Hc_q25）の数値の変動を調査する．これは，Hc_q25 は，クラスタ単位で見た場合に局所的に最も不均衡なクラスタ群の状態を要約する指標であり，サブセット構成の局所的の偏りを検出するために用いる．図 4.4 が，全 γ による Hc_q25 の変動を示す．図より，γ=0 の場合には Hc_q25 が低い値を示し，一部クラスタにおいて同一 ID のサンプルが集中し，局所的な不均衡が生じていることが示唆される．γ を導入することで，Hc_q25 は全体として上昇する傾向を示し，多くの条件においてクラスタ内の ID 多様性が多少ではあるが，改善されていることが確認できる．一方で，γ を過度に大きく設定した場合（γ=0.8 付近）には，Hc_q25 が一時的に低下する挙動も確認できる．

この結果は，Entropy Preservation 制約が，局所的なクラスタ構成に対して有効に機能している一方で，γ が単調に構成の改善をもたらすパラメータではないことを示している．γ を過度に大きくすると，Entropy Preservation 制約が強く働くことでサンプル選択の自由度が低下し，一部のクラスタでは局所的に特定 ID が集中する可能性がある．その結果，Entropy が低いクラスタが生じ，下位部位（Hc_q25）における Entropy の低下として観測される．したがって，γ には適切な範囲が存在する．一方で，γ=0.8 において Hc_q25 が極端に低い値を示す一方で，同条件での人物再識別性能は最も高い値を示している．このことは，Entropy Preservation 制約が全体としては有効に機能している一方で，局所的なクラスタ構成においては，一部偏りが残存する可能性を示唆している．しかし，これらの偏りは学習を著しく阻害するものではなく，性能向上に寄与した可能性がある．

■γ とサブセット全体の ID 多様性（ID Entropy）の関係　最後に，全 γ の値において，ID Entropy の数値の変動を調査する．ID Entropy とは，サブセット全体の ID 分布に基づく Shannon Entropy であり，サブセットに含まれる ID の多様性および均一性を表す指標である．値が大きいほど，多くの ID が均等に含まれていることを示す．図 4.5 に，全 γ による ID Entropy の変動である．ID Entropy は γ の値に関わらず，ほぼ一定であり，理論最大値に近い水準を維持している．これは，γ がサブセット全体の ID 分布を直接制御するためのパラメータではないことを示している．

この結果は，本実験条件（α=0.1，β=0.7）において，サブセット全体の ID 分布がもともと安定しており，γ の変化によってサブセット全体をまとめて見た時に ID 多様性が大きく変化しないことを示している．すなわち，Entropy Preservation 制約の効果は，ID Entropy のようなサブセット全体を見る指標には顕在化しにくく，主にクラスタ内の局所的な構成に現れることがわかる．

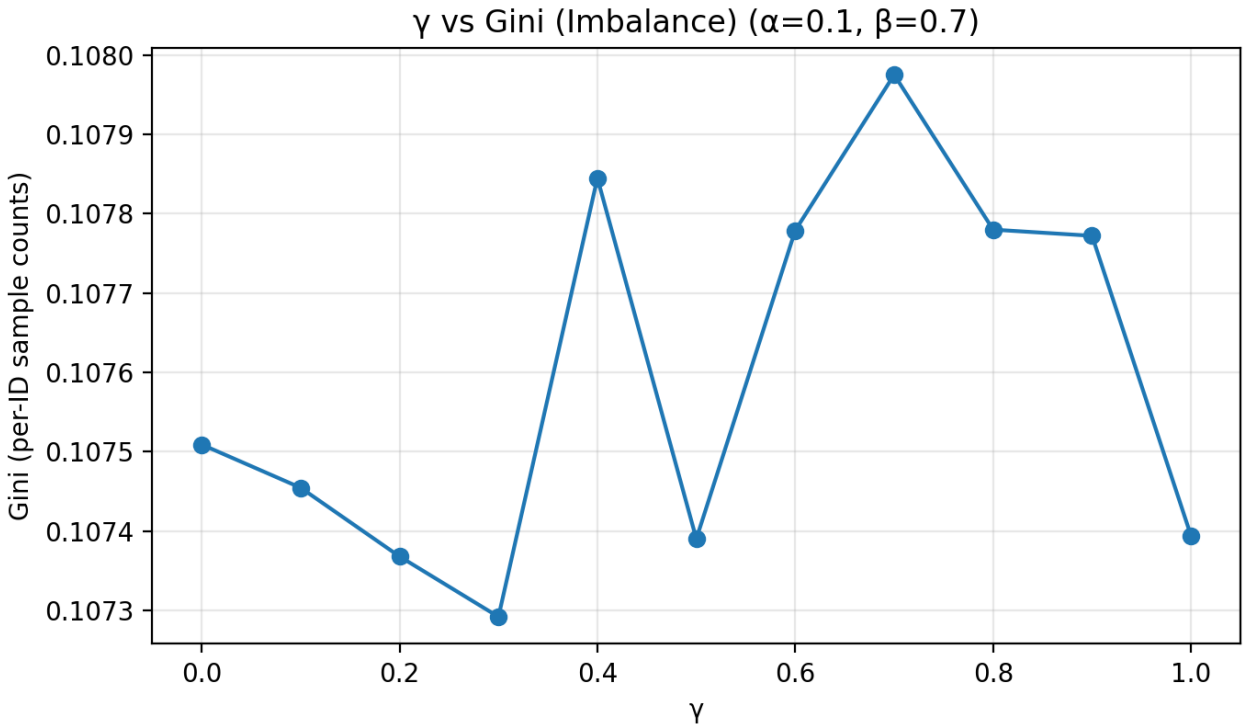

図 4.3　γ vs Gini 係数

■γ sweep 実験のまとめ　Gini，Hc_q25，ID Entropy を総合的に見ることで γ の役割が明確になった．ID Entropy は γ の値に依らず，ほぼ一定の値を示しており，γ の変化によってサブセット全体の ID 分布が著しく偏ることはないことが確認できる．また，Gini 係数についても大きな変動は見られず，γ の導入によって ID 枚不均衡が悪化していないことがわかる．一方で，Hc_q25 は γ に依存して変化しており，γ=0 ではクラスタ内に局所的な不均衡が生じる傾向があり，適切な γ によってその不均衡が抑制されることが明らかとなった．これらの結果から，Entropy Preservation 制約（γ）は，サブセット全体の ID 多様性を増加させるためのパラメータではなく，局所的なクラスタ構成における偏りを抑制するめの制約として機能していることが示唆される．

α sweep

前実験では，Entropy Preservation 制約 γ が，サブセット全体の ID 多様性を増加させるためのパラメータではなく，クラスタ内における局所的な構成崩壊を抑制するための制約として機能していることを示した．本実験では，その知見を踏まえ，γ を適切な値（γ=0.8）に固定した上で，サブセット量を制御するハイパーパラメータ α を変化させ，サブセット構成の代表性（di_median），サブセット全体の ID 多様性（ID Entropy），ID 枚数不均衡（Gini 係数）の観点から，α がサブ

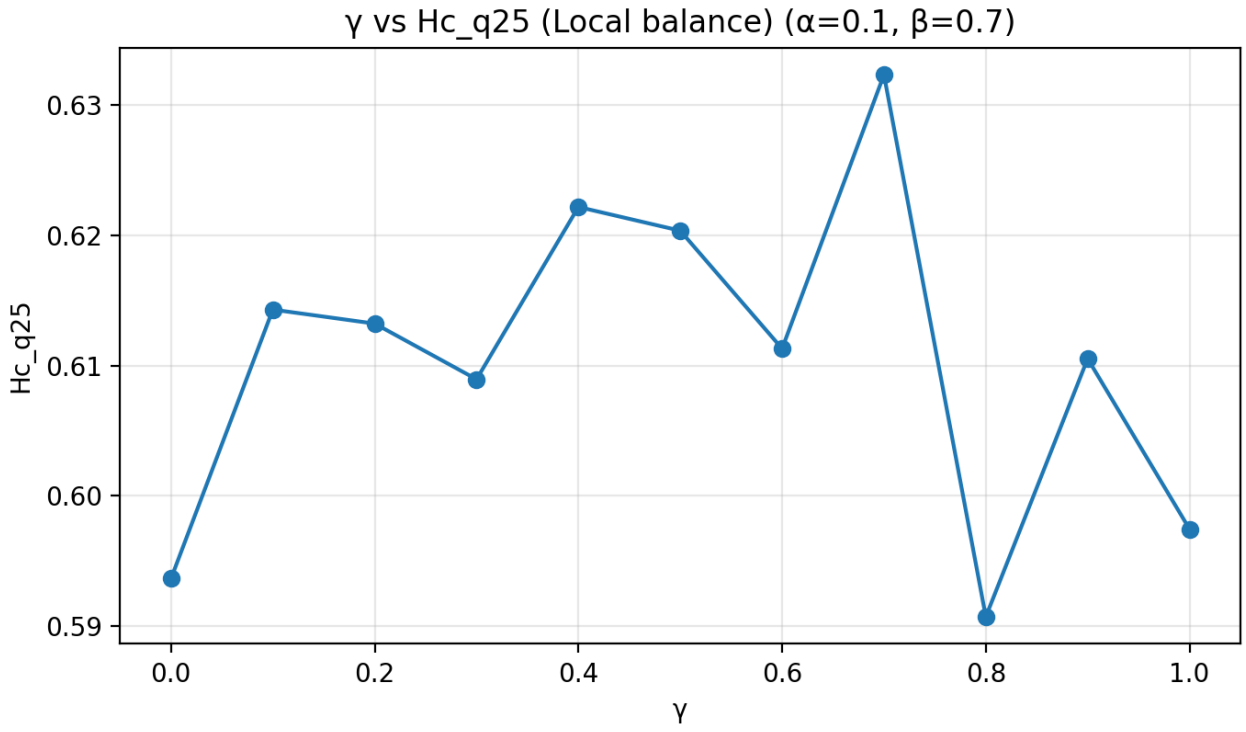

図 4.4　γ vs Hc_q25

セット構成に与える影響を分析する．なお，本実験では代表性に関するパラメータ β を 0.7 に固定している．

■α と代表性指標（di_median）の関係　まず, 図 4.6 に α と di_median の関係を示す．di_median は，サブセット選択前の合成データ全集合に対する代表性を評価する指標であり，値が大きいほど，分布の中心付近に位置するサンプル，つまり代表性が高いサンプルが多く含まれていることを示す．図 4.6 より，α=0.1 の時に di_median が最も高い値を示し，α の増加に伴って緩やかに低下している傾向が確認できる．この挙動は，α を増加させることで，分布の中心に近い代表的なサンプルを維持したまま，分布の周辺に位置するサンプルも少しずつ追加されるため，サブセット全体の分布が緩やかに広がることに起因すると考えられる．このとき，中心的なサンプルが急激に失われるわけではないため，di_median の低下は緩やかなものにとどまっている．すなわち，α を大きく設定することは，サンプル数の増加という観点では有利である一方で，サブセット全体としての代表性を希薄化させる可能性があることを示唆している．

■α とサブセット全体の ID 多様性（ID Entropy）の関係　次に，図 4.7 に α と ID Entropy の関係を示す．ID Entropy はサブセット全体における ID 分布の多様性および均一性を表す指標である．図 4.7 より，α の増加に伴って ID Entropy はわずかに増加する傾向が見られるものの，

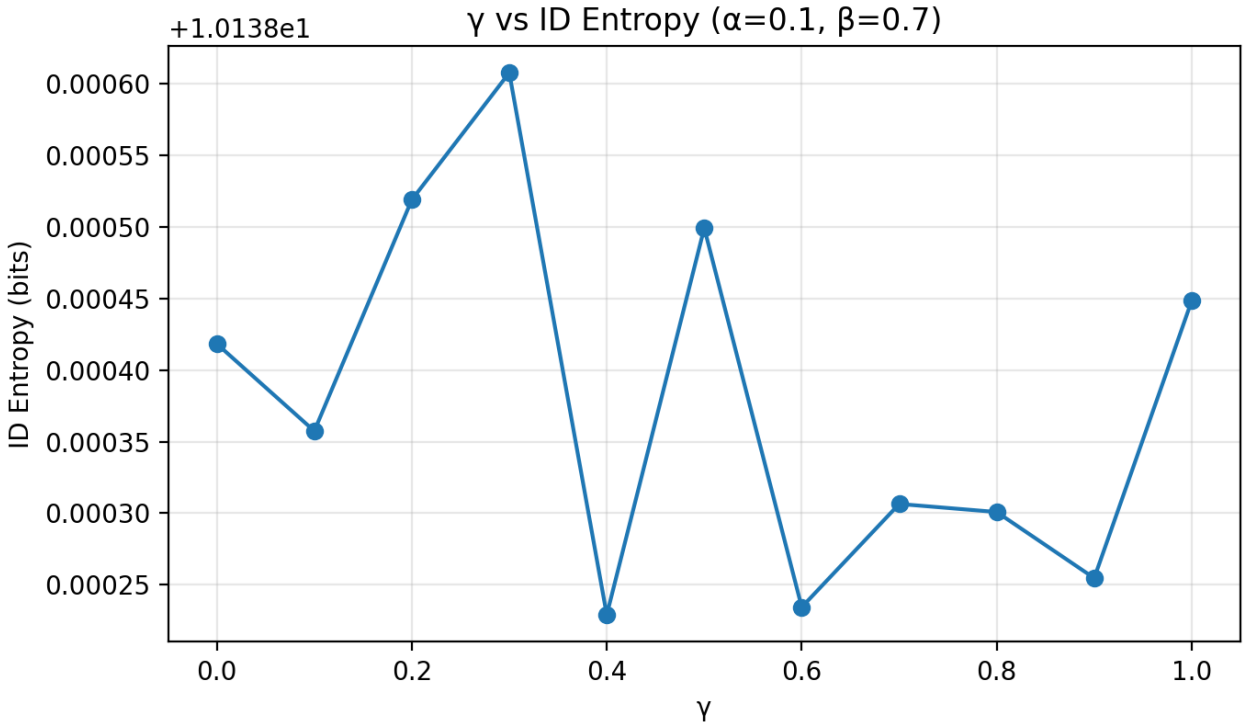

図 4.5　γ vs ID エントロピー

その変動幅は小さく，全体としてはほぼ一定の値を維持していることが確認できる．このことは，本実験条件（β=0.7，γ=0.8）において，α を変化させてもサブセット全体の ID 分布が大きく変化していないことを示している．すなわち，α はサブセットの量を制御するパラメータではあるが，Entropy Preservstion 制約が有効に機能している条件下では，サブセット全体の ID 多様性や均一性に与える影響は限定的となっている．

■α と ID 枚数不均衡（Gini 係数）の関係　図 4.6 に，α と Gini 係数の関係を示す．Gini 係数は，ID ごとのサンプル数分布の不均衡度を表す指標であり，値が小さいほど ID 枚数が均等に分布していることを意味する．図 4.6 より，α の増加に伴って Gini 係数を低下する傾向を示しており，特に α=0.1 から 0.2 にかけて不均衡度が大きく改善していることが確認できる．一方で，α=0.3 以降では低下幅は緩やかとなり，α を増加させることによる均等化の効果は次第に小さくなる．この結果は，α が小さい条件では，限られたサンプル数の中で代表性を優先した選択が行われるため，一部の ID にサンプルが集中しやすい一方で，α をある程度以上に増加させることで，多くの ID がサブセットに含まれ，ID 枚数の偏りが大きく緩和されることを示している．

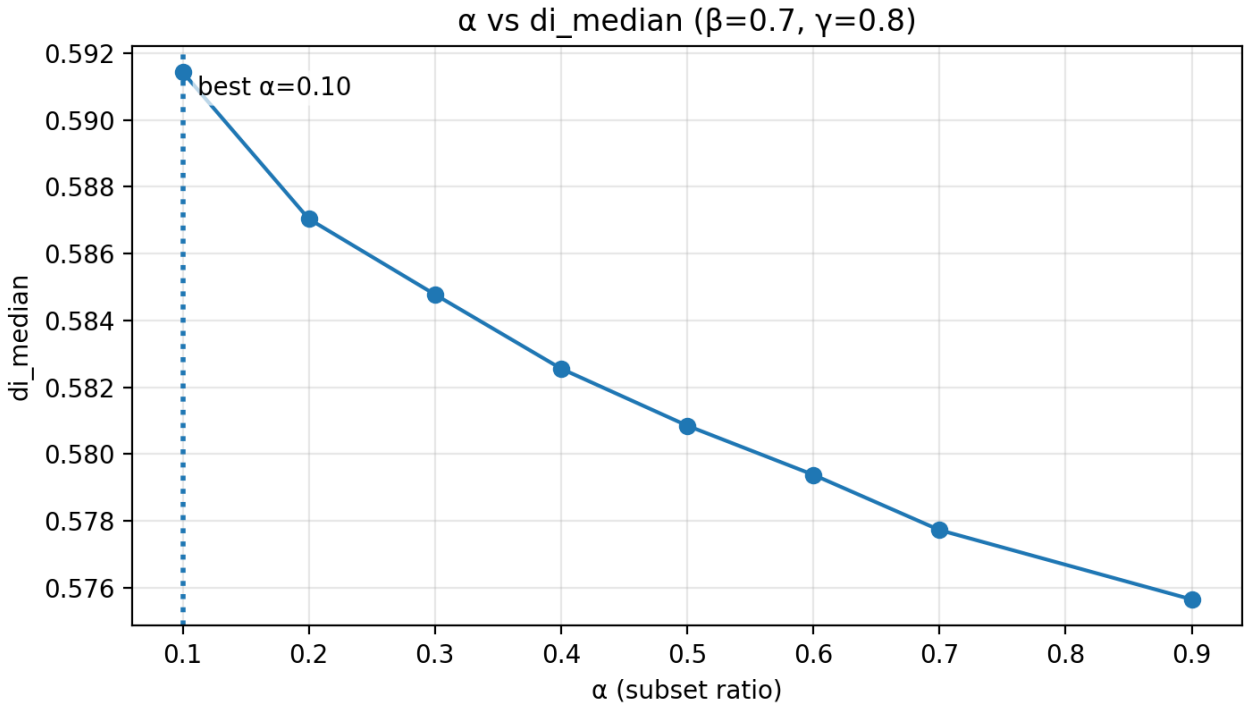

図 4.6　α vs di_median

β sweep

本実験では，γ を適切な値（γ=0.8）に固定し，さらに α=0.1，すなわち代表性が高く性能的にも有効であった条件を基準として，代表性をどの程度優先するかを制御するハイパーパラメータ β を変化させた場合の影響を分析する．以下では，代表性（di_median），サブセット全体の ID 多様性（ID Entropy），ID 枚数不均衡（Gini 係数），およびクラスタ内局所多様性（Hc_q25）の観点から考察を行う．

■β と代表性指標（di_median）の関係　4.9 に β と di_median の関係を示す．β の増加に伴って di_median は緩やかに低下していることが確認できる．ここで，β は，サブセット選択前の合成データ全集合の特徴空間における分布中心への近さを直接最大化するパラメータではなく，代表性を考慮したサブセット構成比を制御する役割を持つ．そのため，β を大きく設定した場合，分布中心付近に位置する代表的なサンプルが限られた範囲に集中し，サブセット全体としての分布の広がりを抑えられることで，di_median が低下する挙動が生じたと考えられる．

■β とサブセット全体の ID 多様性（ID Entropy）の関係　図 4.10 に β と ID Entropy の関係を示す．図 4.10 より，β の増加に伴って ID Entropy は緩やかに増加し，β=0.8 付近ではほぼ緩和する挙動が確認できる．ただし，その変動幅は小さく，β を変化させてもサブセット全体の ID

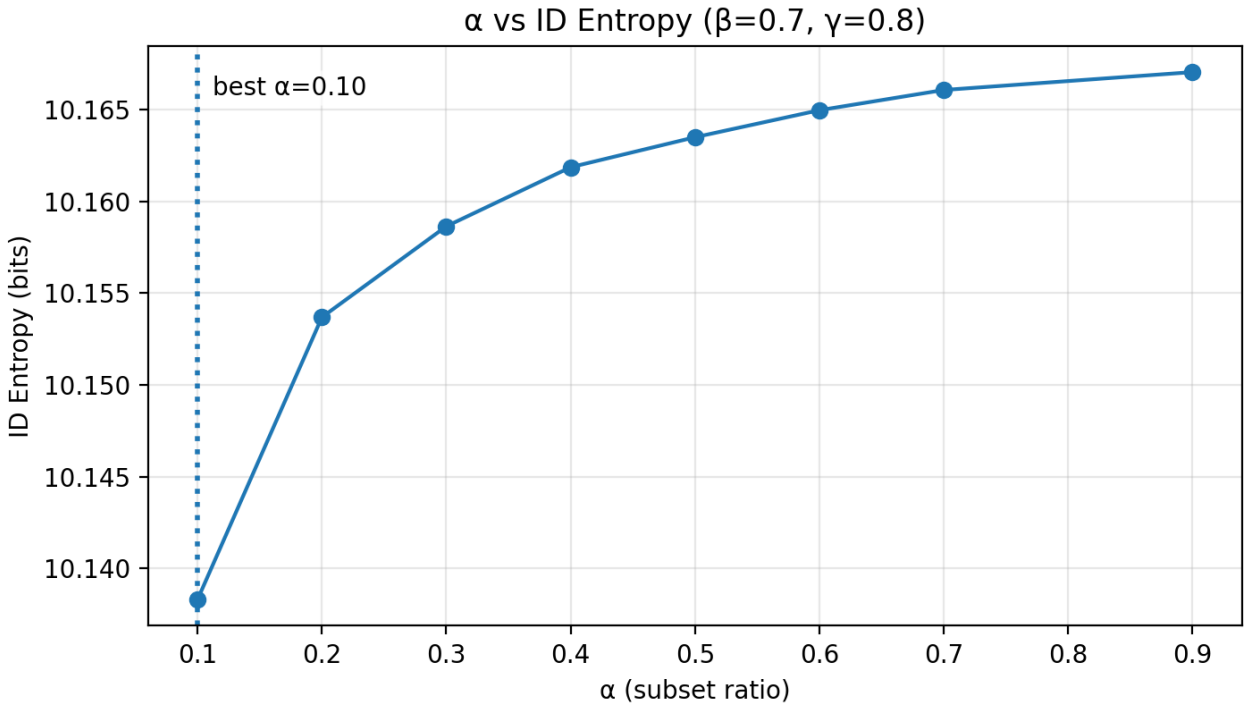

図 4.7　α vs ID エントロピー

多様性が大きく変化していないことがわかる．この結果は，全節までの γ sweep および α sweep の結果と同様に，ID Entropy が主にサブセット全体の規模や γ によって制御される指標であり，β の影響は限定的であることを示している．

■β と ID 枚数不均衡（Gini 係数）の関係　図 4.11 に β と Gini 係数の関係を示す．図 4.11 より，β の増加に伴って Gini 係数は低下する傾向を示しており，特に β=0.0 から 0.7 にかけて，ID 枚数の不均衡が緩和されていることが確認できる．この結果は，β を増加させることで，特定の ID にのみ依存しない形で代表性を考慮したサンプル選択が行われ，結果として ID 枚数の偏りが抑制されていることを示唆している．一方で，β=0.8 以降では，Gini 係数の低下はほぼ止まっており，β=1.0 ではわずかに増加する傾向も観測される．これは，代表性制約が過度に強く働くことで，分布中心付近に位置する限られたサンプルのみが選択候補となり，サブセットを構成する際に選択可能なサンプルの組み合わせが制限されるためと考えられる．その結果，代表的なサンプルを多く含む一部の ID に選択が再び集中し，ID 枚数不均衡が少々増加した可能性がある．

■β とクラスタ内局所多様性（Hc_q25）の関係　図 4.12 に β と Hc_q25 の関係を示す．Hc_q25 は，各クラスタ内の ID 分布に基づく Entropy の下位 25% 分位を表す指標であり，サブセット構成における局所的な偏りを検出するために用いられる．図 4.12 より，β の増加に伴って Hc_q25 は顕著に低下していることが確認できる．特に β=0.4 以降では低下が急激となっており，代表性を

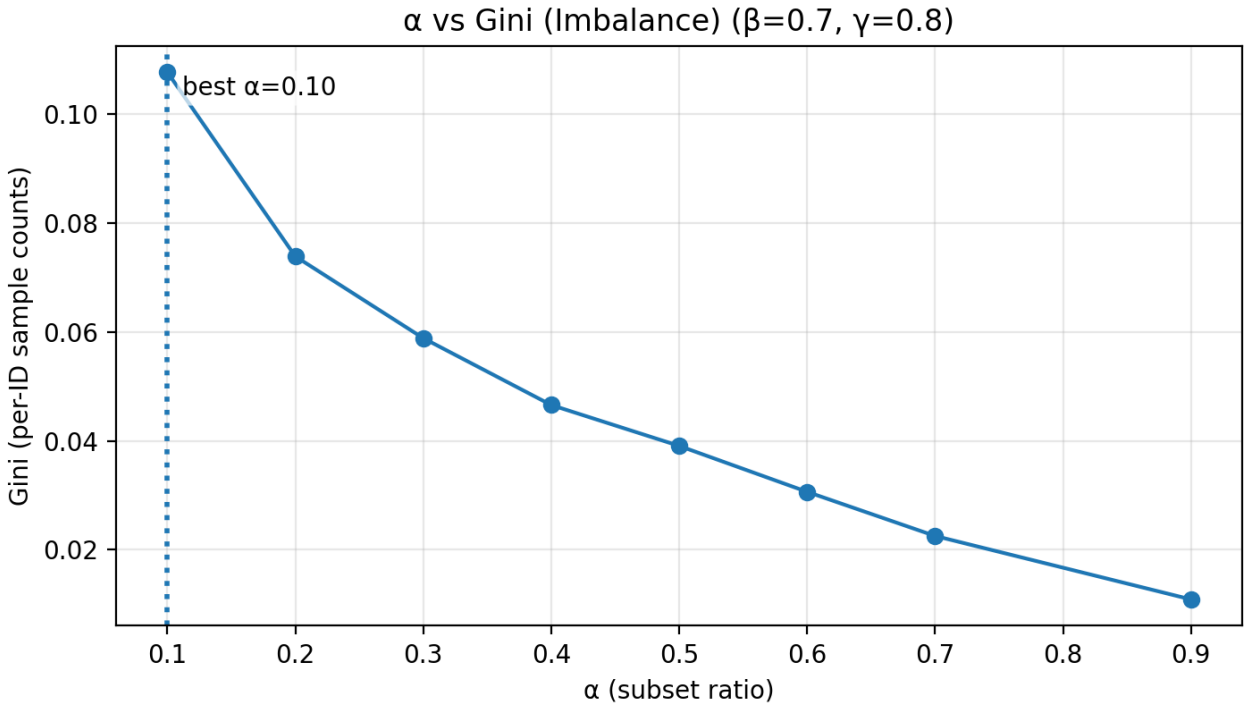

図 4.8　α vs Gini 係数

強く優先することで，同一の ID サンプルが特定クラスタに集中し，クラスタ内局所多様性が損なわれていることが示唆される．この挙動は，γ sweep において確認された Entropy Preservation 制約は局所的な構成崩壊を抑制するという知見と一貫しており，β が大きくなるほど，γ による制約があっても局所構成の歪みが顕在化する可能性を示唆している．すなわち，β は Hc_q25 に対して最も直接的に影響を与えるパラメータであり，代表性を過度に優先することが，局所的なサブセット構成の崩壊につながり得ることが示された．

sweep 実験全体を通した考察

実験 4 にて，γ sweep，α sweep，β sweep の一連の実験結果を総合的に整理し，BDS における各ハイパーパラメータの役割および相互関係について考察する．

まず，γ sweep の結果から，Entropy Preservation 制約 γ は，サブセット全体の ID 多様性を直接増加させるためのパラメータではなく，クラスタ内における局所的な構成崩壊を抑制するための制約として機能していることが明らかになった．Gini 係数や ID Entropy といったサブセット全体を集約して評価する指標は γ の変化に対して大きな変動を示さなかった一方で，Hc_q25 は γ に依存して変化しており，Entropy Preservation 制約の効果が主に局所的なクラスタ構成に現れることが確認された．この結果は，γ が BDS を安定して機能させるための前提条件として重要

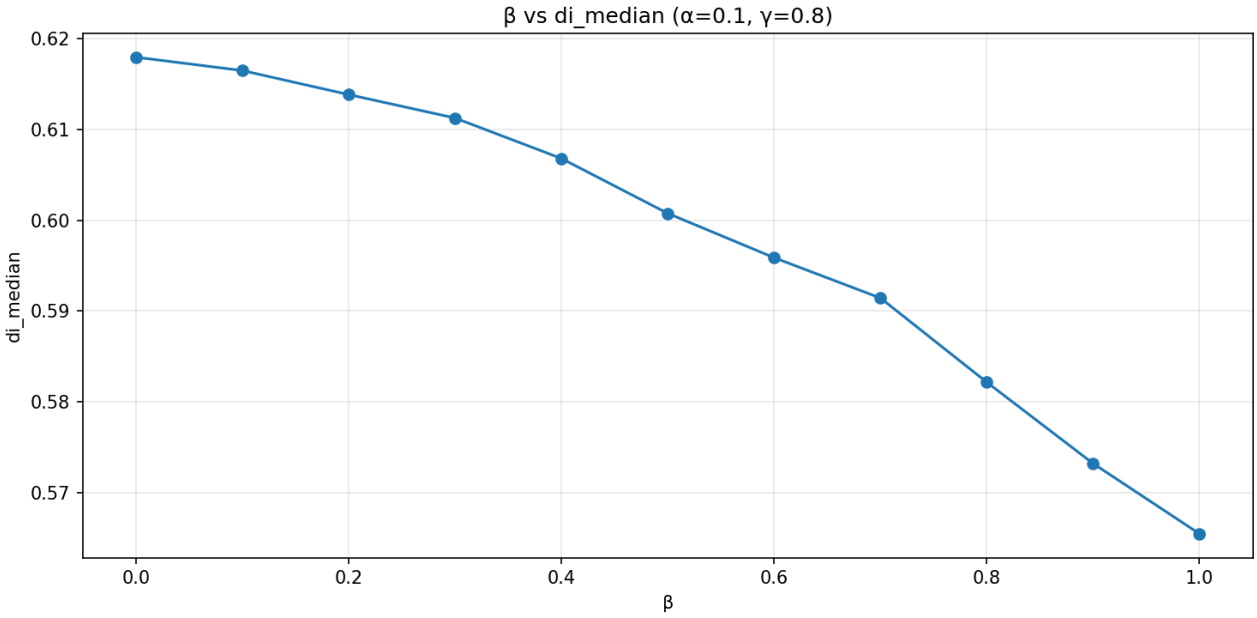

図 4.9　β vs di_median

な役割を担っていることを示している．

次に，α sweep の結果から，α はサブセット量を制御するパラメータであると同時に，代表性，均等性のトレードオフに影響を与えることが示された．α を増加させることで，ID 枚数不均衡は一定程度緩和される一方で，di_median は緩やかに低下し，サブセット全体としての代表性が希薄化する傾向が確認された．また，ID Entropy は α の変化に対してほぼ一定の値を保っており，Entropy Preservation 制約が有効に機能している条件下では，サブセット量の増加が必ずしも ID 多様性の大幅な向上につながらないことが示唆された．これらの結果から，α は単にサブセットを大きくすれば良いというパラメータではなく，代表性を保ったままどの程度までサンプル数を拡張するかを慎重に制御する必要があることが明らかとなった．

さらに β sweep の結果から，β は BDS において代表性をどの程度優先するかを調整するパラメータであり，特に局所的なサブセット構成に強い影響を与えることが示された．β の増加に伴い，di_median は緩やかに低下し，分布中心付近の限られたサンプルに選択が集中することで，サブセット全体の分布の広がりが抑えられる傾向が確認された．一方で，Gini 係数は中程度の β において低下するものの，β を過度に大きくすると改善が停止し，一部の ID に再びサンプルが集中する可能性が示唆された．さらに，Hc_q25 は β の増加に対して顕著に低下しており，代表性を過度に優先することでクラスタ内局所多様性が損なわれ，局所的な構成崩壊が生じやすくなることが示唆された．

これらの結果を総合すると，BDS における各ハイパーパラメータは独立に機能するのではなく，明確に役割分担された上で相互に影響しあっていることがわかる．γ は局所的な構成崩壊を防

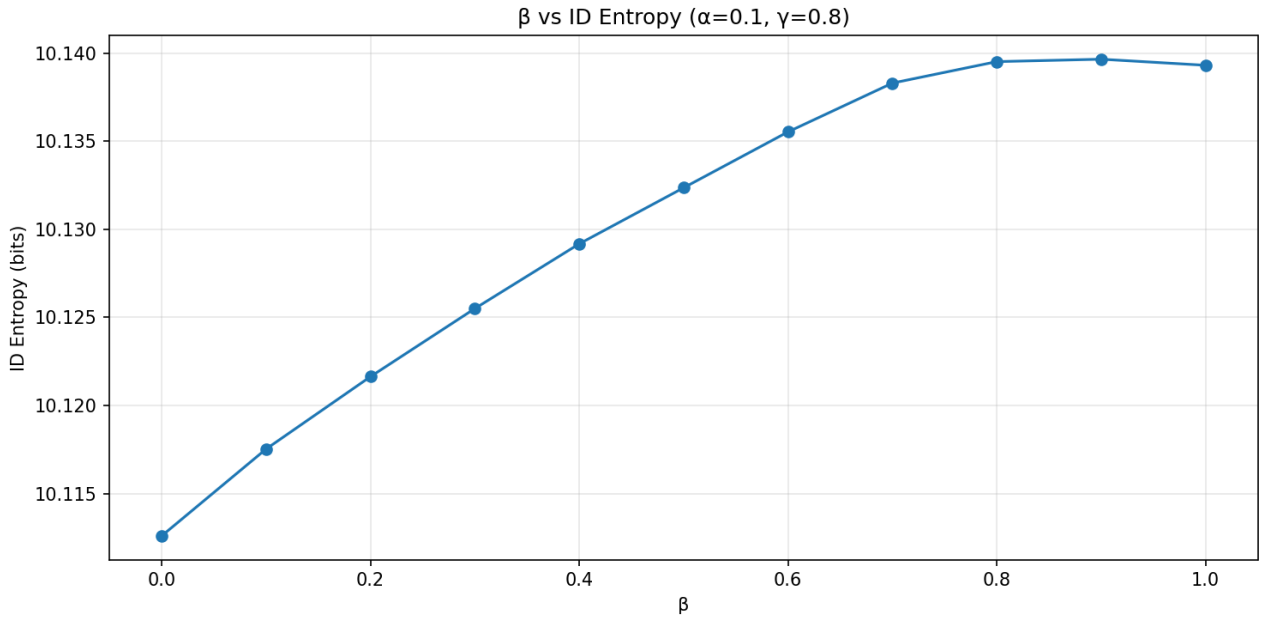

図 4.10　β vs ID Entropy

ぐための制約としてサブセット構成の安定性を担保し，その上で α がサブセット量と代表性のバランスを調整し，β が代表性と局所多様性のトレードオフを制御する役割をになっている．特に，γ による安定化が十分に機能していない条件下では，α や β の効果を適切に評価することが困難になることから，γ は BDS の設計において前提条件となるパラメータであると位置付けられる．

4.4　考察と議論

本章では，提案手法 Balandced Diverse Strategy，BDS の有効性を検証するために実施した一連の実験結果を総合的に考察する．本研究の目的は，合成 ReID データから，実世界データに対して，有効な学習用サブセットを構築するために，代表性，視覚的多様性，ID 多様性をどのように制御すべきかを明らかにすることである．特に，合成データは大量に生成可能である一方で，冗長性や分布の歪みを抱えやすく，それらを無制御に用いた場合には，必ずしも実世界データに対する識別性能の向上に繋がらないという課題がある．

これらの課題に対し，本研究では，サブセット量を制御する α，代表性を制御する β，および局所的な構成崩壊を抑制する Entropy Preservation 制約 γ を導入し，サブセット構成を段階的に分析した．本章では，各実験で得られた結果を単に列挙するのではなく，それらが示す数値的傾向が何を意味しているのか，また，なぜそのような挙動が生じたのかについて整理する．さらに，これらの考察を通して，提案手法 BDS が既存のサブセット選択手法と比較してどのような点で有効であるのか，また，どのような条件下でその効果が発現するのかについて議論する．

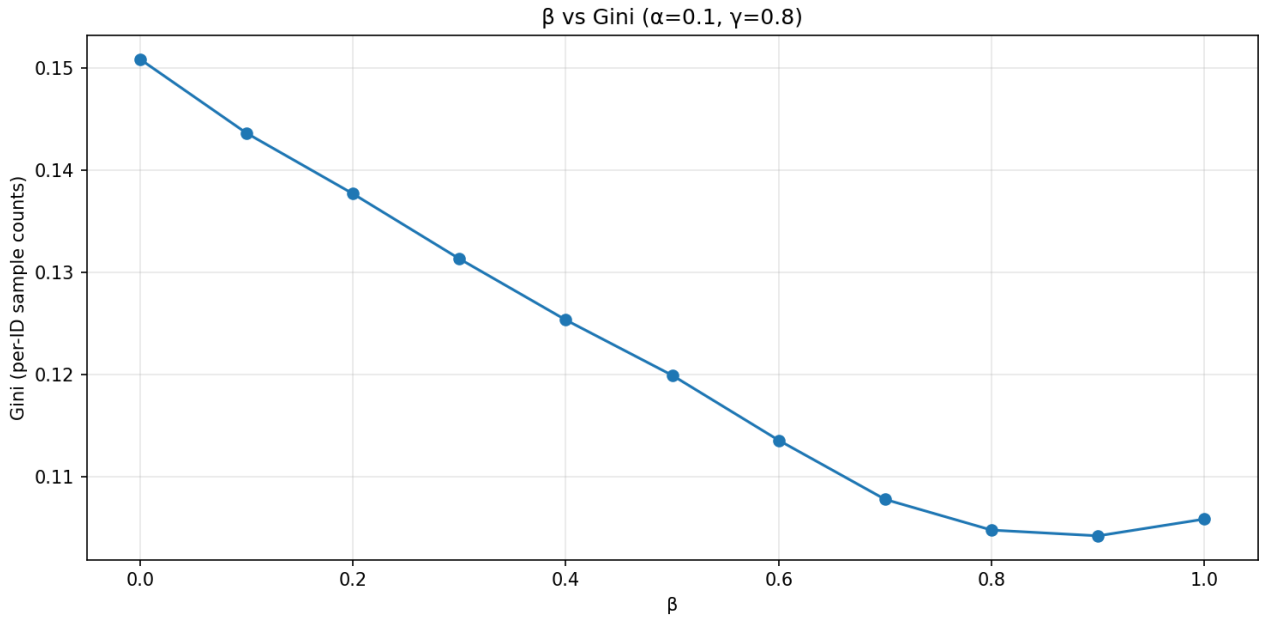

図 4.11　β vs Gini 係数

実験結果より，BDS はランダムサンプリングや単一指標（Core のみ，Diverse のみ等）に基づくサブセット選択と比較して，一貫して高い ReID 性能を示した．この結果は，いずれか一つの設計指標のみを最適化するだけでは，合成データの有効性を引き出せないことを示唆している．アブレーション実験の結果からも明らかなように，代表性のみを考慮した場合には，分布中心付近のサンプルに偏った構成となり，外観変動や ID 多様性が十分に確保されない．一方で，多様性のみを重視した場合には，代表性の低いサンプルが過剰に含まれ，実世界データとの分布乖離が拡大する可能性がある．また，ID 多様性制約のみでは，サブセット全体の構成は安定するものの，学習に有効なサンプルが十分に含まれない場合がある．これに対して，BDS は代表性，視覚的多様性，ID 多様性を同時に制御することで，実世界分布に近く，かつ学習に必要な変動を含んだサブセット構成を実現している点に特徴がある．この統合的な設計が，単一指標では得られなかった性能向上につながったと考えられる．

α sweep の結果から．サブセットサイズを単純に増加させることが，必ずしも ReID 性能の向上につながらないことが示された．特に，α=0.1 という比較的小規模なサブセットにおいて，rank-1 および mAP が最大となった点は重要であると考えられる．この挙動は，合成データにおいては，冗長なサンプルを大量に含めるよりも，代表性が高く，かつ適度な多様性を持つサンプルを厳選することが有効であることを示してる．α を増加させると，サブセット全体の ID 分布や均一性は Entropy Preservation 制約が働いているため，ある程度改善されるものの，同時に分布の周辺部に位置する代表性の低いサンプルも多く含まれるようになる，その結果，サブセット全体としての代表性は緩やかに低下し，性能向上に寄与しにくくなると考えられる．この結果は，「よ

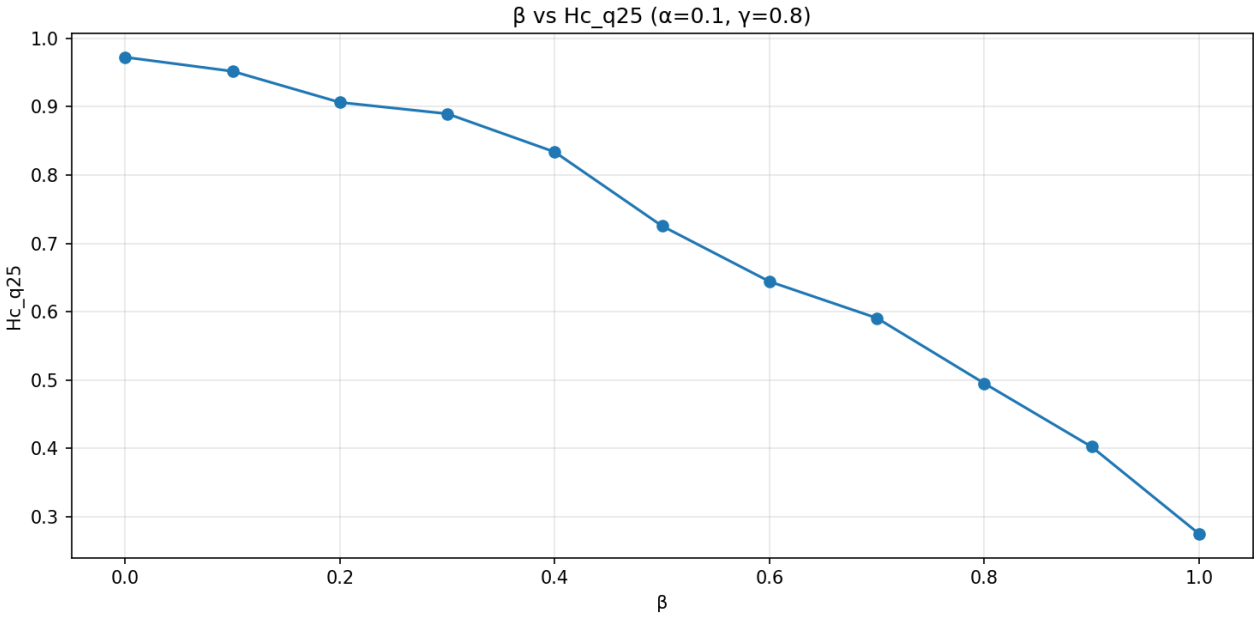

図 4.12　β vs Hc_q25

り多くのデータを用いるほど性能が向上する」という単純な過程が，合成データに対しては必ずしも成立しないことを示しており，本研究のサブセット選択というアプローチの妥当性を裏付けている．

β sweep および γ sweep の結果から，これらのハイパーパラメータは，性能を単調に向上させるためのパラメータではなく，サブセット構成の崩壊を防ぐための制約パラメータとして機能していることが明らかとなった．

γ sweep の結果より，Entropy Preservation 制約は，サブセット全体の ID 多様性を直接増加させるものではなく，クラスタ内における局所的な ID 集中を抑制する役割を果たしていることが示された．特に γ=0 の条件では，Hc_q25 の数値が低く，一部のクラスタにおいて同一 ID が集中する構成崩壊が見られたと考えられる．一方で，適切な γ を導入することで，この局所的不均衡が抑制され，安定したサブセット構成が得られていると考えられる．

β sweep の結果では，β を大きくすることで ID 枚数不均衡（Gini 係数）は，一定程度改善される一方で，クラスタ内局所多様性（Hc_q25）は顕著に低下する挙動が確認された．これは，代表性を過度に優先することで，分布中心付近に位置する限られたサンプルに選択が集中し，サブセット構成の自由度が低下したためと考えられる．

これらの結果を統合すると，γ は BDS が安定して機能するための前提条件であり，β は代表性と局所多様性のトレードオフを調整するパラメータであることがわかる．すなわち，β や γ を極端に設定することは，かえってサブセット構成を歪める可能性があり，適切な範囲での制御が重要である．また，BDS における各ハイパーパラメータは独立に機能するものではなく，γ による

局所安定化を前提とした上で，α によって量を，β によって代表性と視覚的多様性のバランスを調整する構造を持つ頃が明らかとなった．

以上の結果を統合すると，本研究で提案する Balanced Diverse Strategy（BDS）は，既存の Balanced Active Sampling[9] や FPS[10] などの手法と比較して，サブセット構成をより柔軟に制御できる点に特徴がある．既存手法の多くは，幾何学的分散やクラスバランスといった単一の観点に基づいてサンプル選択を行うのに対し，BDS は代表性，視覚的多様性，および ID 多様性を明示的に分離した上で統合的に制御可能であり，実世界データに対して有効な学習用サブセットを構築できる点が本研究の重要な知見である．

一方で，本研究における評価設定については，いくつかの留意点が存在する．本研究では，代表性評価の基準分布として Market-1501 の学習用分割を用い，その分布に近いサンプルを合成データセット FineGPR から選択している．そのため，Market-1501 をテストデータセットとして用いた場合，学習データのサブセット選択とテストデータの分布推定が同一データセットに基づいているという点で，分布レベルでの情報リークが生じている可能性は否定できない．

この点をより厳密に検証するためには，評価に用いるテストデータを Market-1501 に固定したまま，代表性基準として用いる実世界データ分布のみを変更する設定が有効であると考えられる．具体的には，Market-1501 をテストデータとして用いながら，代表性評価に用いる分布を Market-1501 ではなく CUHK03 の学習データから推定し，その分布に基づいて FineGPR から学習用サブセットを選択する，といった構成が考えられる．

このような設定により，テストタスクの難易度を一定に保ったまま，代表性基準の違いがサブセット構成および ReID 性能に与える影響をより直接的に分析することが可能となる．本研究では実験時間の制約により，この設定での検証には至っていないが，BDS のデータセット依存性をより詳細に評価する上で，今後の重要な課題である．

ただし，本研究における代表性評価は，個々の画像や ID に対する直接的な参照を行うものではなく，特徴空間上で推定された平均および共分散に基づく統計的な分布整合性を評価している点に留意する必要がある．したがって，厳密な意味でのサンプルレベルのリークではないものの，評価結果が Market-1501 の分布特性に一定程度依存している可能性は残る．

以上を踏まえると，本研究における評価設定は，代表性評価の妥当性を検証する上で一定の合理性を持つ一方で，基準分布として用いる実世界データセットの選択によっては，分布レベルでの情報リークが疑われ得る点には注意が必要である．したがって，今後の課題として，学習データのサブセット選択とテストデータの分布推定が同一の実世界データセットに依存しないような，より厳密なデータセット設定や評価プロトコルを設計することが重要であると考えられる．

以上の考察より，本研究で提案する BDS は，評価に用いる実世界分布の設計に一定の依存性を持つものの，代表性，視覚的多様性，および ID 多様性を明示的に分離した上で統合的に制御できる点に特徴がある．既存手法の多くが，幾何学的分散やクラスバランスといった単一の観点に基づいてサンプル選択を行うのに対し，BDS はこれらの要素を同時に考慮することで，実世界デー

タに対して有効な学習用サブセットを構築できることを示した.

第 5 章

結論

本研究では，合成 ReID データから実世界データに対して有効な学習用サブセットを構築することを目的として，代表性・視覚的多様性・ID 多様性を統合的に制御するサブセット選択手法 BDS を提案した．BDS は，サブセット量を制御する α，代表性を考慮した構成比を制御する β，および局所的な構成崩壊を抑制する Entropy Preservation 制約 γ の三つのハイパーパラメータによって構成される．

一連の実験を通じて，γ がサブセット全体の ID 多様性を直接増加させるものではなく，クラスタ内における局所的な構成崩壊を防ぐ制約として機能することを明らかにした．また，α は代表性とサブセット量のトレードオフを調整するパラメータであり，γ が適切に設定されている条件下では，サブセット構成の安定性を保ったまま量を増加できることを示した．さらに，β は局所多様性に最も強く影響するパラメータであり，代表性を過度に優先することが，局所構成の歪みにつながる可能性を明らかにした．

これらの結果から，合成データを用いた ReID においては，単にデータ量や代表性を最大化するのではなく，局所的な多様性を維持しながらバランスよくサブセットを構成することが重要であることが示された．BDS は，このような観点を明示的に取り入れたサブセット選択手法として，有効に機能することを確認した．

また，本研究で扱った合成データからのサブセット選択問題は，ReID 技術の社会実装においても重要な意義を持つ．合成データを活用することで，実データへの依存を低減し，プライバシー保護やデータ収集に伴う倫理的課題を緩和しながら，高性能な人物再識別モデルの構築が可能となる．さらに，必要最小限のデータを用いた効率的な学習は，計算資源や学習コストの削減，環境負荷の低減にも寄与する．

今後の課題としては，異なる実世界データセットやドメインに対する一般化性能の検証，特徴抽出器やクラスタリング手法の違いがサブセット構成に与える影響の分析，およびドメインギャップ低減手法と BDS を組み合わせた場合の効果検証が挙げられる．これらの検討を通じて，BDS がより広範な条件下で適用可能なサブセット選択手法であることを示すことが，今後の重要な研究課題である．

謝辞

本修士論文の執筆にあたり、終始ご指導・ご助言を賜りました大木哲史教授に深く感謝申し上げます。研究の進め方や論文の構成に関して多くの貴重なご指摘をいただき、本研究をまとめる上で大きな助けとなりました。

また、本論文の審査にあたり有益なご助言を賜りました副査の先生方に心より御礼申し上げます。さらに、日頃より有意義な議論や助言をいただいた研究室の皆様に感謝いたします。

ね.

2026 年 1 月 30 日

竹田 優那

参考文献

[1] Xiangtan Lin, Pengzhen Ren, Chung-Hsing Yeh, Lina Yao, Andy Song, and Xiaojun Chang. Unsupervised person re-identification: A systematic survey of challenges and solutions. *ACM Computing Surveys*, 2021.

[2] Liang Zheng, Yi Yang, and Alexander G. Hauptmann. Person re-identification: Past, present and future. *arXiv preprint arXiv:1610.02984*, 2016.

[3] Liang Zheng, Liyue Shen, Lu Tian, Shengjin Wang, Jingdong Wang, and Qi Tian. Scalable person re-identification: A benchmark. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, December 2015.

[4] Wei Li, Rui Zhao, Tong Xiao, and Xiaogang Wang. Deepreid: Deep filter pairing neural network for person re-identification. In *CVPR*, 2014.

[5] Longhui Wei, Shiliang Zhang, Wen Gao, and Qi Tian. Person transfer gan to bridge domain gap for person re-identification, 2018.

[6] Xiaoxiao Sun and Liang Zheng. Dissecting person re-identification from the viewpoint of viewpoint. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.

[7] Yanan Wang, Shengcai Liao, and Ling Shao. Surpassing real-world source training data: Random 3d characters for generalizable person re-identification. In *Proceedings of the 28th ACM International Conference on Multimedia (MM 2020)*, pp. 3422–3430, Virtual, Online, United States, 2020. Association for Computing Machinery.

[8] Suncheng Xiang, Dahong Qian, Mengyuan Guan, Biao Yan, Ting Liu, Yuzhuo Fu, and Guanjie You. Less is more: Learning from synthetic data with fine-grained attributes for person re-identification. *ACM Transactions on Multimedia Computing, Communications, and Applications*, Vol. 19, No. 1, pp. 1–20, 2023.

[9] Tao He, Leqi Shen, Guiguang Ding, Zhiheng Zhou, Tianshi Xu, Xiaofeng Jin, and Yuheng Huang. Balanced active sampling for person re-identification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[10] Yue Yao, Tom Gedeon, and Liang Zheng. Large-scale training data search for object re-identification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 15568–15578, 2023.

[11] Sławomir Bak, Peter Carr, and Jean-François Lalonde. Domain adaptation through synthesis for unsupervised person re-identification. In *European Conference on Computer Vision (ECCV)*, pp. 85–102, 2018.

[12] Vu Duy Nguyen, et al. Tackling domain shifts in person re-identification: A survey and analysis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2024.

[13] Jifei Song, Yongxin Yang, Yi-Zhe Song, Tao Xiang, and Timothy M. Hospedales. Generalizable person re-identification by domain-invariant mapping network. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 719–728, 2019.

[14] Timur Mamedov, Anton Konushin, and Vadim Konushin. Remix: Training generalized person re-identification on a mixture of data. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2025.

[15] Yan Qian, Johan Barthélemy, Bo Du, and Jun Shen. A privacy-compliant approach to responsible dataset utilisation for vehicle re-identification. *Digital Transportation and Safety*, Vol. 3, No. 4, pp. 210–219, 2024.

[16] Weijian Deng, Liang Zheng, Qixiang Ye, Guoliang Kang, Yi Yang, and Jianbin Jiao. Image-image domain adaptation with preserved self-similarity and domain-dissimilarity for person re-identification. In *Proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 994–1003, United States, 2018. IEEE/CVF.

[17] Yuval Eldar, Michael Lindenbaum, Moshe Porat, and Yehoshua Y. Zeevi. The farthest point strategy for progressive image sampling. *IEEE Transactions on Image Processing*, Vol. 6, No. 9, pp. 1305–1315, 1997.

[18] Zhedong Zheng, Xiaodong Yang, Zhiding Yu, Liang Zheng, Yi Yang, and Jan Kautz. Joint discriminative and generative learning for person re-identification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2138–2147. IEEE/CVF, 2019.

[19] Yixiao Ge, Zhuowan Li, Haiyu Zhao, Guojun Yin, and Shuicheng Yan. Fd-gan: Pose-guided feature distilling gan for robust person re-identification. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1222–1231, 2018.

[20] Changxing Zhang, Liang Zhu, Shengcai Zhang, and Wei Yu. Pac-gan: An effective pose augmentation scheme for unsupervised cross-view person re-identification. *Neurocomputing*, Vol. 387, pp. 22–39, 2020.

関連業績

【 学会発表 】
発表タイトル

　2026 年 3 月　（発表予定）　ライフインテリジェンスとオフィス情報システム研究会（LOIS）
竹田 優那，内田 秀継，名田 元，安倍 登樹，山田 茂史，西垣 正勝，大木 哲史